



PREGRADO / INGENIERÍA DE SISTEMAS Y COMPUTACIÓN
INGENIERÍA INDUSTRIAL

Protección de la Privacidad en Datos de Ubicación mediante Privacidad Diferencial: Evaluación de Mecanismos de Perturbación.

por

Carol Sofía Florido Castro

Asesores:

Valérie Gauthier Umaña, Juan Fernando Perez Bernal

2025

Índice general

Contenido	I
Lista de Figuras	V
Índice de figuras	V
Lista de Tablas	VII
Índice de tablas	VII
1. Introducción	1
2. Privacidad Diferencial	4
2.1. Modelos de Privacidad Diferencial: <i>privacidad diferencial central</i> (CDP) y <i>privacidad diferencial local</i> (LDP)	5
2.2. Overview del contenido de la tesis	6
2.3. Mecanismo de Laplace para Perturbación de Coordenadas	7
2.3.1. Análisis de la gráfica de perturbación	9
2.4. Algoritmo Pivot Sampling para Privacidad en Trayectorias (TP)	11
2.4.1. Conceptos Fundamentales	11
2.4.2. Perturbación Direccional	12
2.4.3. Determinación del Dominio de Perturbación	13
2.4.4. Selección de Granularidad Óptima	14
2.4.5. Composición Final y Análisis de Privacidad	15
2.4.6. Análisis de la gráfica de perturbación	16
2.5. Anchor-Based Pivot Sampling (ATP)	18
2.5.1. Cálculo del Anclaje	18
2.5.2. Dominio restringido de perturbación	19
2.5.3. Determinación del Radio Adaptativo	20
2.5.4. Calibración del Radio	22
2.5.5. Ajuste del Radio Perturbado	24
2.5.6. Análisis de la gráfica de perturbación	26

3. Análisis del Comportamiento del Presupuesto de Privacidad	28
3.1. Metodología de Análisis del Presupuesto de Privacidad ϵ	29
3.1.1. Métricas de Evaluación	29
3.1.2. Conjunto de Datos	29
3.1.3. Normalización de Epsilon a Escala Unificada	30
3.2. Mecanismo de Laplace	30
3.2.1. Importancia de la Escala de Coordenadas	31
3.2.2. Selección de Parámetros de Privacidad mediante Radio Medio Deseado	32
3.2.3. Evaluación de Métricas	32
3.3. Pivot Sampling	35
3.3.1. Composición en Privacidad Diferencial Local	35
3.3.2. Mapeo de Parámetros a Escala Unificada	36
3.3.3. Evaluación de Métricas	36
3.3.4. Análisis Comparativo del Comportamiento	39
3.4. Anchor-Based Pivot Sampling (ATP)	40
3.4.1. Mapeo de Parámetros a Escala Unificada	40
3.4.2. Evaluación de Métricas	40
3.4.3. Análisis Comparativo del Comportamiento	44
4. Análisis Experimental Graficas Origen-Destino	46
4.1. Descripción del Experimento y Parámetros de Configuración	46
4.1.1. Configuración del Presupuesto de Privacidad	46
4.1.2. Variación del tamaño de paso y análisis multiescala	47
4.2. Construcción de las matrices OD y evaluación de resultados	48
4.2.1. Análisis de Resultados del Mecanismo de Laplace para Perturbación de Coordenadas	49
4.2.2. Análisis de Resultados del Algoritmo Pivot Sampling para Privacidad en Trayectorias (TP)	51
4.2.3. Análisis de Resultados del Algoritmo Anchor-Based Pivot Sampling (ATP)	54
4.3. Comparación Global de los Mecanismos de Privacidad Diferencial	57
5. Análisis Grafico de las Trayectorias	60
5.1. Parámetros de Configuración	60
5.2. Tipos de Visualización	61
5.3. Interacción con la Herramienta	63
5.4. Consideraciones finales	65
6. Conclusiones y Trabajo Futuro	66
6.1. Discusión de Resultados	66
6.2. Herramienta de Visualización	67
6.3. Aplicaciones Potenciales	67
6.4. Limitaciones del Estudio	68

ÍNDICE GENERAL	III
6.5. Trabajo Futuro	68
6.6. Conclusión Final	69
Bibliografía	70

Índice de figuras

2.1. Flujo de información del mecanismo de privacidad diferencial aplicado a coordenadas de ubicación.	5
2.2. Trayectoria original y perturbada con $\epsilon = 1$ y $N = 20$ puntos. Los círculos y cruces indican los puntos de inicio y fin de cada trayectoria, respectivamente. .	10
2.3. Trayectoria original y perturbada mediante Pivot Sampling con $\epsilon = 20$ y $N = 20$ puntos. Los círculos indican los puntos de inicio, mientras que las cruces marcan los puntos finales de cada trayectoria. La dispersión refleja la perturbación independiente de pivotes y la restricción direccional de puntos no pivote. . . .	17
2.4. Trayectoria original y perturbada mediante el mecanismo ATP con $\epsilon = 20$ y $N = 20$ puntos. Los círculos indican los puntos iniciales y las cruces los puntos finales de cada trayectoria.	27
3.1. Métricas de error y desempeño del Mecanismo de Laplace bajo distintos valores de ϵ	33
3.2. Métricas de error y desempeño del algoritmo Pivot Sampling bajo distintos valores del presupuesto de privacidad efectivo ϵ_{eff}	37
3.3. Métricas de error y desempeño del algoritmo ATP bajo distintos valores del presupuesto de privacidad efectivo ϵ_{eff}	41
4.1. Resultados del Algoritmo Laplace para Perturbación de Coordenadas. Se ilustran las métricas de error (MAE, MAE normalizado, error relativo y norma de Frobenius normalizada).	50
4.2. Resultados del Algoritmo Pivot Sampling para Privacidad en Trayectorias (TP). Se ilustran las tres métricas de error (MAE normalizado, error relativo y norma de Frobenius normalizada).	53
4.3. Resultados del Algoritmo Anchor-Based Pivot Sampling (ATP). Se ilustran las métricas de error (MAE, MAE normalizado, error relativo y norma de Frobenius normalizada).	56
5.1. Ejemplo de matriz Origen–Destino generada por la herramienta.	61
5.2. Mapa de calor de celdas destino.	62
5.3. Mapa de calor de celdas Origen.	62

5.4. Mapa combinado de flujos Origen–Destino con superposición de celdas origen y destino.	63
5.5. Mapa de diferencia absoluta por celda entre matriz OD original y perturbada. .	63
5.6. Botón para alternar visualizaciones.	64
5.7. Panel para cambiar parámetros de visualización y privacidad.	64
5.8. Interfaz para alternar entre datos originales y perturbados.	64
5.9. Selector de algoritmo en la interfaz.	65
5.10. Información adicional al hacer click sobre una celda.	65

Índice de tablas

2.1. Asignación de puntos en el proceso de intercambio	12
3.1. Métricas utilizadas para evaluar las trayectorias perturbadas.	29
3.2. Escala unificada de normalización del presupuesto de privacidad ϵ	30
3.3. Mapeo de niveles de privacidad del Mecanismo de Laplace: radio medio deseado, valores de ϵ calculados, y escala unificada.	32
3.4. Mapeo de niveles de privacidad para Pivot Sampling: valores de k , ϵ efectivo calculado, y escala unificada.	36
3.5. Mapeo de niveles de privacidad para ATP: valores de k , ϵ efectivo calculado, y escala unificada.	40
4.1. Configuración del presupuesto de privacidad utilizada en este capítulo. Se emplean los mismos valores de ϵ definidos en el Capítulo 3. Para los algoritmos basados en LDP, el presupuesto efectivo se calcula como $\epsilon_{\text{efectivo}} = k \times N$, donde N corresponde al número de puntos de cada trayectoria.	47
4.2. Valores del tamaño de paso utilizados en el experimento y su interpretación en términos de resolución espacial.	47
5.1. Valores del tamaño de paso utilizados en el experimento y su interpretación en términos de resolución espacial.	60
5.2. Configuración del presupuesto de privacidad utilizada en este capítulo. Para los algoritmos basados en LDP, el presupuesto efectivo se calcula como $\epsilon_{\text{efectivo}} = k \times N$, donde N corresponde al número de puntos de cada trayectoria.	61

Capítulo 1

Introducción

La proliferación de aplicaciones móviles y servicios basados en ubicación ha transformado radicalmente la manera en que los datos personales son recolectados, procesados y utilizados. Desde que los dispositivos móviles se convirtieron en extensiones inseparables de la vida cotidiana, la recopilación continua de información de ubicación se ha vuelto no solo común, sino esperada [1]. Navegadores GPS, plataformas de movilidad, redes sociales, aplicaciones de citas, servicios de entrega y sistemas de publicidad basada en proximidad dependen del acceso constante a los datos de localización de los usuarios. Esta dependencia, sin embargo, ha convertido la ubicación en uno de los vectores más vulnerables para la exposición involuntaria de información personal.

A diferencia de otros tipos de datos, los registros de ubicación permiten inferir aspectos profundamente sensibles y estructurales de la vida de un individuo: sus hábitos diarios, patrones de desplazamiento, domicilio, lugar de trabajo, prácticas religiosas, estado de salud e incluso sus vínculos sociales o políticos. Estudios recientes han demostrado que basta una pequeña cantidad de puntos geográficos para reidentificar a una persona con alta probabilidad, incluso si los datos han sido anonimizados. Por ejemplo, se ha comprobado que con tan solo cuatro puntos espaciotemporales seleccionados al azar se puede identificar de manera única al 95 % de los individuos en un conjunto de datos de 1,5 millones de personas, evidenciando la singularidad de los patrones de movilidad humana [2]. Esto ha despertado crecientes preocupaciones en la comunidad académica, en organismos reguladores, empresas y entre los propios usuarios, quienes, si bien desean servicios personalizados y contextualmente relevantes, también exigen mayor control sobre su privacidad.

Este escenario se enmarca en un contexto más amplio de tensiones entre innovación tecnológica y derechos fundamentales. A medida que se afianzan regulaciones como el Reglamento General de Protección de Datos (GDPR) en Europa, la Ley de Privacidad del Consumidor de California (CCPA) y otros marcos legales emergentes en América Latina y Asia, las organizaciones enfrentan una presión creciente para implementar técnicas que permitan explotar valor en los datos sin comprometer la privacidad individual [3]. En este punto, la privacidad diferencial ha emergido como uno de los paradigmas más robustos y formalmente garantizados para proteger los datos personales [4].

La **privacidad diferencial**, al introducir ruido estadísticamente controlado sobre los datos o las respuestas a consultas, permite realizar análisis útiles sin revelar información específica sobre ningún individuo. Esta técnica garantiza que los resultados agregados reflejen tendencias generales y patrones de comportamiento sin comprometer la identidad o los datos de una persona concreta, estableciendo un equilibrio entre *utilidad analítica* y *protección de la privacidad*. Su adopción por parte de empresas líderes como **Apple** [5] y **Google** [6] ha reforzado su legitimidad técnica y operativa, mostrando aplicaciones prácticas en entornos de datos reales. Apple utiliza la privacidad diferencial para mejorar productos y servicios de Apple Intelligence, como Genmoji, herramientas de generación de imágenes y resúmenes de texto en correos electrónicos. La empresa aplica ruido controlado y técnicas de agregación para recolectar solo señales agregadas de los dispositivos de los usuarios que han optado en su programa de Device Analytics. De esta manera, Apple puede identificar tendencias de uso, evaluar la efectividad de sus modelos de IA y optimizar funcionalidades, sin acceder a datos individuales ni contenido personal, garantizando que la información sensible, como prompts o emails específicos, nunca se vincule a un usuario particular. Por su parte, Google (BigQuery) aplica la privacidad diferencial en consultas de análisis de grandes conjuntos de datos, limitando la contribución de cada entidad a múltiples grupos, restringiendo los valores agregados y añadiendo ruido a los resultados finales. También elimina grupos con pocas entidades para evitar la reidentificación. Estas medidas permiten a empresas y analistas obtener insights significativos sobre comportamientos y tendencias de grupos de usuarios sin exponer información individual, lo que es crucial en contextos de riesgo de reidentificación y para cumplir con regulaciones de privacidad. En conjunto, estas aplicaciones muestran que la privacidad diferencial no solo es un estándar teórico, sino una herramienta estratégica y operativa para empresas que buscan maximizar el valor de sus datos mientras protegen la privacidad de sus usuarios, fortaleciendo la confianza y cumpliendo con marcos regulatorios como GDPR y CCPA.

A nivel institucional, Estados Unidos adoptó privacidad diferencial para proteger los datos del Censo 2020, reemplazando métodos tradicionales como el “swapping” de registros. Esto permitió garantizar la confidencialidad de los ciudadanos incluso a nivel de bloques de censo, aunque introdujo cierta pérdida de precisión en unidades geográficas muy pequeñas, especialmente entre grupos minoritarios. Este caso demuestra cómo la privacidad diferencial puede aplicarse a datos reales y críticos, equilibrando protección y utilidad [7].

En particular, proteger trayectorias de usuarios bajo el modelo de privacidad diferencial plantea desafíos técnicos únicos. Las trayectorias presentan una fuerte dependencia espacio-temporal, alta dimensionalidad y complejidad estructural. Además, los usuarios tienen distintos niveles de tolerancia a la perturbación, dependiendo del contexto de uso, el tipo de aplicación y sus propias percepciones de riesgo. Por ello, se requiere evaluar cuidadosamente los mecanismos disponibles, entendiendo cómo afectan no solo la privacidad garantizada, sino también la utilidad práctica de los datos para distintos tipos de servicios.

En este proyecto, se propone comparar distintos métodos de privacidad diferencial aplicados a datos de ubicación, con el fin de evaluar cómo afectan los análisis realizados a partir de las trayectorias obtenidas y qué tan bien se adaptan a diferentes perfiles de usuario. Al

integrar criterios cuantitativos como la distancia esperada, la pérdida de precisión espacial y la preservación de patrones de movilidad, junto con parámetros personalizables de privacidad, esta tesis busca contribuir al diseño de sistemas que protejan los datos de ubicación de forma flexible, robusta y centrada en el usuario. Para facilitar esta evaluación, se ha desarrollado una **herramienta interactiva** que permite visualizar trayectorias GPS, aplicar distintos algoritmos de privacidad diferencial y observar de manera gráfica el impacto de los mecanismos sobre los patrones de movilidad. El análisis se realizará utilizando **matrices Origen–Destino** para caracterizar los flujos de movilidad y evaluar cómo se conservan los patrones espaciales y de desplazamiento. Asimismo, se explorará el comportamiento de los algoritmos bajo diferentes escenarios y se comparará de manera gráfica su desempeño, permitiendo identificar ventajas, limitaciones y el grado de distorsión introducido por cada mecanismo. Finalmente, se pretende ofrecer lineamientos que orienten la implementación práctica de mecanismos de privacidad diferencial en sistemas de movilidad, geolocalización y análisis urbano, asegurando un equilibrio entre innovación, utilidad y protección de los derechos individuales.

Capítulo 2

Privacidad Diferencial

La Privacidad Diferencial (DP, por sus siglas en inglés) es un marco matemático diseñado para proteger la información individual dentro de un conjunto de datos, garantizando que el resultado de cualquier análisis estadístico no se vea significativamente afectado por la inclusión o exclusión de un solo individuo. En palabras de Dwork [8], una función satisface privacidad diferencial si la probabilidad de obtener un determinado resultado es casi la misma independientemente de si un registro individual está o no presente en la base de datos. Formalmente, un mecanismo aleatorizado K satisface ϵ -privacidad diferencial si, para toda pareja de bases de datos D y D' que difieren en una sola fila, y para cualquier subconjunto de posibles salidas S , se cumple que

$$\Pr[K(D) \in S] \leq e^\epsilon \times \Pr[K(D') \in S],$$

en donde el parámetro ϵ (épsilon) cuantifica el nivel de privacidad, controlando el máximo factor por el cual pueden diferir las probabilidades de obtener un resultado al modificar un único dato en el conjunto. Valores pequeños ($\epsilon < 1$) garantizan mayor privacidad al hacer las salidas casi indistinguibles, mientras que valores mayores ($\epsilon > 5$) permiten mayor precisión pero reducen la protección. Es decir, ϵ determina cuánto puede revelar un dato perturbado sobre la posición real del usuario. En el contexto de datos de ubicación, este principio puede aplicarse para proteger la privacidad de usuarios que comparten sus coordenadas geográficas con servicios que dependen de información basada en localización, como aplicaciones de navegación, recomendaciones cercanas o análisis de movilidad urbana. A partir de esto, se considera que los datos de ubicación de los usuarios son protegidos mediante un mecanismo aleatorizado K que garantiza ϵ -privacidad diferencial. De esta manera, cualquier análisis realizado sobre los datos liberados no permite inferir la ubicación exacta de ningún individuo, preservando su información sensible. Por ejemplo, los lugares visitados, etiquetas semánticas asociadas (hospital, iglesia o protesta) y actividades inferidas a partir de la localización quedan protegidos.

La Figura 2.1 ilustra el flujo de información conceptual del mecanismo de privacidad diferencial aplicado a coordenadas de ubicación.




Figura 2.1: Flujo de información del mecanismo de privacidad diferencial aplicado a coordenadas de ubicación.

Formalmente, K puede definirse como una función aleatorizada:

$$K : X \rightarrow \mathcal{P}(Z)$$

donde X representa el conjunto de ubicaciones reales (por ejemplo, coordenadas (lat, lon)) y $\mathcal{P}(Z)$ es el conjunto de distribuciones de probabilidad sobre las coordenadas liberadas Z . El mecanismo produce una salida $z \in Z$ que se utiliza en análisis o servicios, equilibrando privacidad y utilidad sin asumir que cada usuario individual aplica la perturbación. Desde la perspectiva del flujo de información cuantitativa, K puede modelarse como un canal con entrada x y salida z , donde la salida puede incluir generalizaciones espaciales, por ejemplo, pasando de coordenadas exactas a una zona, barrio o ciudad.

2.1. Modelos de Privacidad Diferencial: *privacidad diferencial central* (CDP) y *privacidad diferencial local* (LDP)

La literatura distingue principalmente dos enfoques para la aplicación de la privacidad diferencial: *privacidad diferencial central* (CDP) y *privacidad diferencial local* (LDP) [9]. En el modelo de *privacidad diferencial central* (CDP), se asume la existencia de un administrador de base de datos confiable que tiene acceso directo a los datos individuales. Dicho administrador aplica un mecanismo aleatorizado K que garantiza ϵ -privacidad diferencial antes de liberar cualquier resultado o estadístico agregado. Este modelo es adecuado cuando existe una entidad de confianza que puede custodiar la información sensible y aplicar las perturbaciones necesarias para preservar la privacidad. Sin embargo, en muchos escenarios no existe una parte central confiable, o se busca evitar la agregación de datos sensibles en un solo repositorio. En estos casos se adopta el modelo de *privacidad diferencial local* (LDP), también conocido como *modelo completamente distribuido*. En este enfoque, cada usuario mantiene el control sobre su propio dato y aplica un mecanismo de aleatorización local, denominado *randomizador local* R , que transforma su información antes de compartirla. Formalmente, un ϵ -*randomizador local* $R : X \rightarrow W$ es un algoritmo que satisface privacidad diferencial sobre una base de datos de tamaño uno, es decir, sobre un único registro [9, Sección 12.1]. En el modelo de LDP, las interacciones entre el algoritmo y los datos se realizan a través de un *oráculo de randomización local* $LR_D(\times, \times)$, que toma como entrada un índice i y un randomizador local R , y devuelve una respuesta w generada de acuerdo con la distribución $R(x_i)$. Si el algoritmo

realiza múltiples invocaciones al oráculo sobre el mismo individuo con diferentes randomizadores $\{R_1, R_2, \dots, R_k\}$, la privacidad total del proceso se obtiene mediante la **composición aditiva del parámetro de privacidad**

$$\epsilon_{\text{total}} = \epsilon_1 + \epsilon_2 + \dots + \epsilon_k.$$

esta propiedad, conocida como *teorema de composición secuencial* [10], refleja que cada interacción adicional con los datos implica una pérdida acumulativa de privacidad. En el contexto de la *privacidad diferencial local* (LDP), donde cada usuario aplica de manera independiente el mecanismo de aleatorización sobre su propio dato, esta pérdida se vuelve especialmente relevante. Cada vez que un usuario publica una nueva coordenada perturbada o una nueva trayectoria, se utiliza una parte del presupuesto total de privacidad, lo que incrementa progresivamente el riesgo de inferir información sobre la ubicación real. Por esta razón, en escenarios donde se perturban múltiples puntos, es necesario considerar valores de ϵ más grandes que compensen el número de perturbaciones realizadas. En otras palabras, a medida que aumenta la cantidad de coordenadas perturbadas, el modelo de *privacidad diferencial local* (LDP) requiere un ϵ global mayor para mantener un nivel aceptable de utilidad en los datos liberados. Dwork y Roth [9, Sección 12.1] destacan que, aunque la *privacidad diferencial local* (LDP) ofrece mayores garantías al eliminar la necesidad de una entidad central confiable, sufre una pérdida más rápida de utilidad debido a esta composición aditiva. En el marco de la perturbación de trayectorias, esto implica que el diseño del mecanismo debe equilibrar cuidadosamente el nivel de ruido inyectado con el número de puntos publicados, de modo que se mantenga un balance razonable entre privacidad y precisión espacial.

2.2. Overview del contenido de la tesis

Esta tesis aborda la protección de la privacidad en datos de ubicación mediante el marco de *Privacidad Diferencial* (DP), explorando tanto los modelos centralizados (CDP) como locales (LDP). Se estudian mecanismos probabilísticos de perturbación de coordenadas, incluyendo el *Mecanismo de Laplace*, *Pivot Sampling* y *Anchor-Based Pivot Sampling*, evaluando su desempeño en términos del balance entre privacidad y utilidad. Se analiza detalladamente el papel del presupuesto de privacidad ϵ , destacando cómo su configuración afecta la magnitud del ruido introducido y la pérdida de información en trayectorias de usuarios. A lo largo de la tesis, se presentan experimentos sobre trayectorias reales de Beijing, donde se construyen matrices Origen–Destino para cuantificar los flujos entre celdas y servir como base del análisis gráfico. Estas matrices permiten evaluar la distorsión espacial introducida por los mecanismos de perturbación y facilitan la comparación entre algoritmos. Además, se desarrollan visualizaciones gráficas interactivas que permiten explorar y evaluar el impacto de la perturbación en los datos espaciales, ilustrando la relación entre precisión, privacidad y configuración de parámetros experimentales. Finalmente, se proporcionan herramientas visuales que ayudan a comprender el comportamiento de los distintos mecanismos de privacidad diferencial.

2.3. Mecanismo de Laplace para Perturbación de Coordenadas

El mecanismo de Laplace para protección de privacidad en coordenadas [11] se enmarca dentro del modelo de **privacidad diferencial central** (CDP) y se fundamenta en la adición controlada de ruido siguiendo una distribución de Laplace. Dado un punto original $x \in \mathbb{R}^2$ y un parámetro de privacidad $\epsilon > 0$, el proceso genera un punto perturbado z mediante una transformación probabilística. El mecanismo de perturbación implementado sigue el enfoque propuesto en [11]. La densidad de probabilidad para el punto perturbado z viene dada por

$$D_\epsilon(z|x) = \frac{\epsilon^2}{2\pi} e^{-\epsilon d(x,z)},$$

donde $d(x, z) = \sqrt{(x_1 - z_1)^2 + (x_2 - z_2)^2}$ es la distancia euclidiana entre los puntos x y z . El término $\frac{\epsilon^2}{2\pi}$ actúa como factor de normalización, asegurando que la función de densidad de probabilidad sea válida y que la probabilidad total se integre a 1. Esta formulación garantiza que los puntos más cercanos al original tengan mayor probabilidad de ser seleccionados (debido al término $e^{-\epsilon d(x,z)}$), mientras que los más distantes presentan una probabilidad que decae exponencialmente con la distancia.

A partir de lo anterior, para implementar eficientemente este mecanismo en el contexto de datos de ubicación, se debe utilizar una representación en coordenadas polares centradas en x . Un punto z se expresa como (r, θ) , donde r es la distancia radial desde x y θ el ángulo polar. La densidad conjunta en estas coordenadas se factoriza como

$$D_\epsilon(r, \theta) = \underbrace{\frac{1}{2\pi}}_{\text{uniforme en ángulo}} \times \underbrace{\epsilon^2 r e^{-\epsilon r}}_{\text{distribución radial}}.$$

La generación del punto perturbado aprovecha esta factorización. Primero se selecciona un ángulo θ uniformemente en $[0, 2\pi)$. Para la componente radial, se utiliza la función de distribución acumulativa

$$C_\epsilon(r) = 1 - (1 + \epsilon r)e^{-\epsilon r}.$$

Mediante el método de transformada inversa, se genera un valor uniforme $p \in [0, 1)$ y se resuelve $C_\epsilon(r) = p$ para obtener el radio

$$r = -\frac{1}{\epsilon} \left(W_{-1} \left(\frac{p-1}{e} \right) + 1 \right),$$

donde W_{-1} es la rama negativa de la función W de Lambert, definida como la función inversa de $f(W) = We^W$ para $W \leq -1$. Es decir, para cualquier $y \in [-1/e, 0)$ se cumple que $W_{-1}(y)e^{W_{-1}(y)} = y$, con $W_{-1}(y) \leq -1$. Finalmente, las coordenadas cartesianas del punto perturbado se calculan como

$$z = x + (r \cos \theta, r \sin \theta).$$

Este mecanismo preserva la privacidad de la ubicación, garantizando que los puntos generados no revelan con certeza la posición original. En particular, los puntos más cercanos a la posición

original x tienen mayor probabilidad de ser seleccionados, mientras que los puntos más lejanos aparecen con probabilidad que disminuye exponencialmente con la distancia. El parámetro ϵ controla el nivel de ruido introducido: valores más grandes hacen que los puntos perturbados estén más cerca del original (menos protección), mientras que valores más pequeños producen una mayor dispersión (más privacidad).

Ejemplo ilustrativo. Consideremos un punto original $x = (0, 0)$ y un presupuesto de privacidad $\epsilon = 1$. Para generar un punto perturbado, primero se obtiene un ángulo θ muestreado uniformemente en el intervalo $(0, 2\pi)$; en este caso, supongamos que $\theta = \pi/4$ (45°). Luego se genera un valor $p \sim \text{Uniforme}(0, 1)$, obteniendo $p = 0.5$. A partir de este valor, se resuelve la ecuación $1 - (1 + r)e^{-r} = 0.5$, cuyo resultado es $r \approx 1.67835$. Finalmente, se calculan las coordenadas cartesianas perturbadas como

$$z = (0 + 1.67835 \cos(\pi/4), 0 + 1.67835 \sin(\pi/4)) \approx (1.1868, 1.1868).$$

Este resultado muestra cómo el punto original $(0, 0)$ se desplazó a $(1.1868, 1.1868)$ mediante el mecanismo de perturbación, manteniendo la privacidad diferencial.

Conversión de coordenadas geográficas a un sistema local en metros

Las coordenadas GPS están expresadas en *grados* de latitud y longitud. Sin embargo, estas unidades no son uniformes en términos de distancia: un grado de latitud corresponde aproximadamente a 111 km, mientras que un grado de longitud varía con la latitud, siendo máximo en el ecuador y reduciéndose hacia los polos. Por este motivo, una pequeña perturbación numérica en grados puede traducirse en un desplazamiento muy grande en metros, lo que complica el control de la magnitud del ruido introducido por el mecanismo de Laplace. Para que el parámetro ϵ tenga un significado físico claro, como por ejemplo “introducir un ruido medio de 20 m”, se realiza primero una proyección a un sistema de coordenadas local y plano, medido en metros. Para trayectorias que cubren áreas relativamente pequeñas (como recorridos dentro de una ciudad), se puede utilizar la proyección *equiangular*, que aproxima la superficie terrestre como un plano tangente en un punto de referencia (λ_0, φ_0) , elegido aquí como el primer punto de la trayectoria. La conversión de latitud-longitud a coordenadas planas (x, y) en metros se realiza como

$$x = (\lambda - \lambda_0) \times \cos(\varphi_0) \times R, \quad y = (\varphi - \varphi_0) \times R,$$

donde λ y φ son la longitud y latitud (en radianes), λ_0 y φ_0 son las coordenadas del punto de referencia, y $R \approx 6,371,000$ m es el radio medio de la Tierra. Una vez aplicada la perturbación en metros mediante el mecanismo de Laplace, es necesario regresar a coordenadas geográficas para su visualización en un mapa. Para ello, se invierten las fórmulas anteriores

$$\varphi = \frac{y}{R} + \varphi_0, \quad \lambda = \frac{x}{R \times \cos(\varphi_0)} + \lambda_0,$$

y posteriormente se convierten φ y λ a grados. Con la trayectoria expresada en coordenadas locales (x, y) , se aplica el mecanismo de Laplace. En este sistema, la magnitud esperada del desplazamiento radial $E[r]$ se relaciona con el parámetro de privacidad ϵ_m (expresado en m^{-1}) como

$$E[r] = \frac{2}{\epsilon_m}.$$

Por ejemplo, si se desea un desplazamiento medio de 20 m, se calcula

$$\epsilon_m = \frac{2}{20} = 0.1 \text{ m}^{-1}.$$

Para entender cómo se deriva la anterior formula, es necesario considerar que en coordenadas polares (r, θ) centradas en el punto real, la densidad conjunta del radio y el ángulo se expresa como

$$f_{R,\Theta}(r, \theta) = \frac{\epsilon_m^2}{2\pi} r e^{-\epsilon_m r},$$

donde $r \geq 0$ y $\theta \in [0, 2\pi)$. Al integrar sobre θ se obtiene la densidad marginal del radio

$$f_R(r) = \epsilon_m^2 r e^{-\epsilon_m r}.$$

La magnitud esperada del desplazamiento radial se calcula entonces como

$$E[r] = \int_0^\infty r f_R(r) dr = \epsilon_m^2 \int_0^\infty r^2 e^{-\epsilon_m r} dr.$$

Usando la fórmula general

$$\int_0^\infty r^n e^{-ar} dr = \frac{n!}{a^{n+1}}, \quad a > 0,$$

y considerando $n = 2$ y $a = \epsilon_m$, se tiene

$$\int_0^\infty r^2 e^{-\epsilon_m r} dr = \frac{2}{\epsilon_m^3}.$$

Sustituyendo en la expresión de $E[r]$

$$E[r] = \epsilon_m^2 \times \frac{2}{\epsilon_m^3} = \frac{2}{\epsilon_m}.$$

Por lo tanto, la magnitud esperada del desplazamiento radial está inversamente relacionada con el parámetro de privacidad

$$E[r] = \frac{2}{\epsilon_m}.$$

2.3.1. Análisis de la gráfica de perturbación

La Figura 2.2 muestra el efecto del mecanismo de Laplace aplicado a una trayectoria diagonal de $N = 20$ puntos con un presupuesto de privacidad $\epsilon = 1$. Se observa que los puntos perturbados se dispersan alrededor de la trayectoria original, reflejando la naturaleza aleatoria

del ruido Laplace. Cada punto se aleja de su posición original siguiendo aproximadamente la densidad radial exponencial esperada del mecanismo. Dado el valor relativamente bajo de ϵ , la dispersión es amplia, lo que incrementa la privacidad pero reduce la precisión de la trayectoria. A pesar de la adición de ruido, la tendencia general de la trayectoria diagonal se mantiene, evidenciando que el mecanismo conserva la forma global de la trayectoria y solo altera la ubicación individual de los puntos. Los marcadores más grandes para los puntos iniciales y finales permiten identificar claramente la orientación de la trayectoria, mostrando que el mecanismo respeta la secuencia temporal de los puntos y no genera inversiones en el orden de la trayectoria. El valor del parámetro ϵ influye directamente en la dispersión de los puntos: con $\epsilon = 1$, el desplazamiento medio esperado es considerable, como se aprecia en la figura. Incrementar ϵ reduciría la dispersión, acercando los puntos perturbados a sus posiciones originales y disminuyendo la privacidad diferencial, mientras que valores menores de ϵ aumentarían la dispersión, incrementando la protección de los datos individuales.




Figura 2.2: Trayectoria original y perturbada con $\epsilon = 1$ y $N = 20$ puntos. Los círculos y cruces indican los puntos de inicio y fin de cada trayectoria, respectivamente.

En resumen, la gráfica evidencia cómo el mecanismo de Laplace introduce ruido de manera controlada, preservando la privacidad de cada coordenada individual, mientras mantiene la coherencia global de la trayectoria. Esta visualización permite comprender intuitivamente el balance entre precisión y privacidad controlado por el parámetro ϵ .

2.4. Algoritmo Pivot Sampling para Privacidad en Trayectorias (TP)

El algoritmo *Pivot Sampling* es un mecanismo de **privacidad diferencial local** (LDP) que protege trayectorias geográficas mediante perturbación en dos etapas: perturbación independiente de puntos pivote y perturbación direccional de puntos no pivote. Esta explicación se fundamenta en lo propuesto por [12].

2.4.1. Conceptos Fundamentales

Dada una trayectoria original $\tau = p_i \in \mathcal{P} \mid 1 \leq i \leq |\tau|$, se define como una secuencia ordenada de puntos p_i que pertenecen a un dominio espacial $\mathcal{P}$, el cual representa el conjunto de todas las ubicaciones posibles. Cada punto p_i está compuesto por un par de coordenadas (x_i, y_i) que indican su posición en el espacio bidimensional. La longitud de la trayectoria, denotada por $|\tau|$, corresponde al número total de puntos que la conforman. Primero, el algoritmo crea dos copias idénticas τ' y τ^* de τ . En cada copia se selecciona un subconjunto de puntos seleccionados alternadamente conocidos como **puntos pivote**, (ej. puntos con índice par o impar) que se perturban independientemente usando el Mecanismo Exponencial (EM)

$$Pr[\hat{p} = r] = \frac{\exp\left(\frac{\epsilon_{ind} \times u(p, r)}{2\Delta u}\right)}{\sum_{r' \in \mathcal{P}} \exp\left(\frac{\epsilon_{ind} \times u(p, r')}{2\Delta u}\right)}. \quad (2.1)$$

En el contexto de perturbación de trayectorias, se considera un punto real original p perteneciente a la trayectoria y su correspondiente versión perturbada $\hat{p}$. Ambos puntos forman parte del dominio espacial $\mathcal{P}$, que contiene todas las ubicaciones posibles. Dentro de este dominio, r y r' representan dos puntos candidatos que podrían ser seleccionados como versiones perturbadas del punto original. Para decidir entre estos candidatos, se utiliza una función de utilidad definida como $u(p, r) = -\text{dist}(p, r)$, donde $\text{dist}(p, r)$ representa la distancia Haversine entre los puntos $p = (lat_1, lon_1)$ y $r = (lat_2, lon_2)$. Esta distancia se calcula mediante la fórmula

$$\text{dist}(p, r) = 2R \arcsin \left(\sqrt{\sin^2 \left(\frac{\Delta lat}{2} \right) + \cos(lat_1) \cos(lat_2) \sin^2 \left(\frac{\Delta lon}{2} \right)} \right), \quad (2.2)$$

donde R es el radio de la Tierra (aproximadamente 6,371 km), $\Delta lat = lat_2 - lat_1$ y $\Delta lon = lon_2 - lon_1$, expresadas en radianes. El signo negativo en la función de utilidad permite que el mecanismo exponencial favorezca la selección de puntos cercanos, ya que estos presentan mayor utilidad (menor distancia).

La sensibilidad de la función (2.1), denotada como Δu , se define como el máximo cambio posible en la utilidad al comparar dos candidatos diferentes respecto a un mismo punto, es decir, $\Delta u = \max_{p, r, r'} |u(p, r) - u(p, r')|$. Finalmente, el parámetro ϵ_{ind} representa el presupuesto de privacidad asociado a la perturbación de cada punto de manera independiente, lo que determina el grado de protección garantizado frente a la inferencia adversaria. Para seleccionar los puntos de pivote que servirán de base para la perturbación, el algoritmo implementa un mecanismo de

intercambio estratégico que reparte los puntos de la trayectoria original entre las dos copias: τ' y τ^* . De manera inicial, los puntos pares de la trayectoria se asignan como pivotes en τ' (es decir, $\mathcal{P}_{ind}^{\tau'} = \{p_2, p_4, \dots\}$), mientras que los impares se utilizan como pivotes en τ^* (es decir, $\mathcal{P}_{ind}^{\tau^*} = \{p_1, p_3, \dots\}$). Note que se cumple con la relación $\mathcal{P}_{ind}^{\tau^*} = \mathcal{P} - \mathcal{P}_{ind}^{\tau'}$, que asegura una cobertura total y no redundante del conjunto de puntos. Durante el proceso de perturbación, en la trayectoria τ' los puntos pares son perturbados de forma independiente mediante el Mecanismo Exponencial, mientras que los puntos impares aprovechan la información direccional proveniente de sus vecinos ya perturbados. En la trayectoria τ^* ocurre el proceso inverso: los puntos impares se perturban de forma independiente y los pares utilizan la información de sus vecinos impares para guiar su perturbación. Este intercambio de roles promueve un equilibrio entre privacidad y utilidad, ya que evita que toda la trayectoria dependa únicamente de perturbaciones independientes o correlacionadas.

Ejemplo ilustrativo. Considere una trayectoria $\tau = \{p_1, p_2, p_3, p_4, p_5\}$. En la **Tabla 2.1** se muestra cómo se asignan los puntos entre las dos copias τ' y τ^* durante el proceso de intercambio estratégico: los puntos pares de la trayectoria original se eligen como **pivotes** en τ' (p_2 y p_4) y los puntos impares se asignan como **no pivotes** (p_1, p_3, p_5), mientras que en τ^* ocurre el proceso inverso, con los impares como pivotes (p_1, p_3, p_5) y los pares como no pivotes (p_2, p_4). Esta distribución se puede visualizar directamente en la tabla.

Tabla 2.1: Asignación de puntos en el proceso de intercambio

Copia	Puntos Pivote	Puntos No Pivote
τ'	p_2, p_4	p_1, p_3, p_5
τ^*	p_1, p_3, p_5	p_2, p_4

2.4.2. Perturbación Direccional

Para los puntos no pivote, el algoritmo introduce ruido en la dirección relativa respecto a los puntos pivote vecinos, con el fin de preservar la privacidad manteniendo cierta coherencia espacial. Para ello, el espacio angular se divide en un número finito de sectores iguales, cada uno representando una dirección posible. La dirección real de un punto se asigna inicialmente a uno de estos sectores discretos según su ángulo geométrico. Esto por medio de la siguiente formula

$$\mathcal{D} = \{0, 1, \dots, |\mathcal{D}| - 1\}, \text{ donde cada } d \in \mathcal{D} \text{ cubre } \left[(2d - 1) \frac{\pi}{|\mathcal{D}|}, (2d + 1) \frac{\pi}{|\mathcal{D}|} \right]. \quad (2.3)$$

Luego, se aplica el mecanismo de respuesta aleatorizada k -RR, que introduce incertidumbre en la dirección reportada: con alta probabilidad (controlada por el parámetro de privacidad ϵ), se selecciona el sector verdadero, pero con una pequeña probabilidad se elige otro sector al azar. Esto asegura que el valor final comunicado no revele exactamente la dirección original, dificultando la identificación precisa del punto, pero sin perder completamente la información direccional, lo que ayuda a preservar la utilidad de la trayectoria perturbada. El mecanismo

k-RR opera entonces como

$$Pr[\mathcal{K}(d) = d'] = \begin{cases} \frac{e^\epsilon}{|\mathcal{D}| - 1 + e^\epsilon} & \text{si } d = d' \text{ (dirección correcta)} \\ \frac{1}{|\mathcal{D}| - 1 + e^\epsilon} & \text{si } d \neq d' \text{ (dirección incorrecta)}, \end{cases} \quad (2.4)$$

donde:

- $\mathcal{K}$: Mecanismo de perturbación
- ϵ : Presupuesto de privacidad para direcciones
- d : Dirección original (índice del sector)
- d' : Dirección reportada

Ejemplo ilustrativo. Supongamos que el espacio angular se divide en $|\mathcal{D}| = 8$ sectores. Cada sector cubre un ángulo de $\frac{2\pi}{8} = \frac{\pi}{4}$ radianes (45 grados). Si un punto tiene una dirección relativa de $\theta = \frac{5\pi}{8}$, entonces este ángulo cae dentro del sector

$$\left[(2d - 1) \frac{\pi}{|\mathcal{D}|}, (2d + 1) \frac{\pi}{|\mathcal{D}|} \right] = \left[(2d - 1) \frac{\pi}{8}, (2d + 1) \frac{\pi}{8} \right].$$

Buscando el valor de d que satisface esta desigualdad para $\theta = \frac{5\pi}{8}$, obtenemos $d = 3$, pues

$$\left[(2 \times 3 - 1) \frac{\pi}{8}, (2 \times 3 + 1) \frac{\pi}{8} \right] = \left[\frac{5\pi}{8}, \frac{7\pi}{8} \right].$$

Por tanto, la dirección original se asigna al sector $d = 3$. Luego, usando el mecanismo k -RR con $\epsilon = 1.0$, se calcula la probabilidad de reportar la dirección verdadera como

$$Pr[\mathcal{K}(3) = 3] = \frac{e^1}{7 + e^1} \approx \frac{2.718}{7 + 2.718} \approx 0.28$$

y la probabilidad de reportar cualquiera de los sectores incorrectos ($d' \neq 3$) como

$$Pr[\mathcal{K}(3) = d'] = \frac{1}{7 + e^1} \approx \frac{1}{9.718} \approx 0.103.$$

Este ejemplo muestra cómo se introduce aleatoriedad en la dirección sin eliminar completamente la información espacial.

2.4.3. Determinación del Dominio de Perturbación

Para cada punto no pivote p_j , el dominio de perturbación $\mathcal{P}^j$ se define como el conjunto de posibles ubicaciones en el espacio que están restringidas a un rango angular específico determinado por las direcciones perturbadas provenientes de sus puntos pivote vecinos. Este dominio se calcula utilizando un procedimiento que, dado un pivote perturbado $\hat{p}_k$ y una dirección angular perturbada $\hat{d}_{k,j}$, obtiene todos los puntos $p \in \mathcal{P}$ cuya dirección relativa con respecto a $\hat{p}_k$ cae dentro del sector angular delimitado por los ángulos $\theta_{\min}$ y $\theta_{\max}$. Estos

límites se determinan según el índice del sector angular $\hat{d}_{k,j}$ y la cantidad total de sectores $|\mathcal{D}|$, de modo que

$$\theta_{\min} = (2\hat{d}_{k,j} - 1) \frac{\pi}{|\mathcal{D}|}, \quad \theta_{\max} = (2\hat{d}_{k,j} + 1) \frac{\pi}{|\mathcal{D}|}.$$

El dominio de perturbación final para el punto p_j resulta de la intersección de los sectores angulares definidos por los pivotes vecinos $\hat{p}_{j-1}$ y $\hat{p}_{j+1}$, es decir,

$$\mathcal{P}^j = S(\hat{p}_{j-1}, \hat{d}_{j-1,j}) \cap S(\hat{p}_{j+1}, \hat{d}_{j+1,j}),$$

donde $S(\hat{p}_i, \hat{d}_{i,j}) = \{p \in \mathcal{P} : \theta(\hat{p}_i, p) \in I(\hat{d}_{i,j})\}$ representa el conjunto de puntos cuyo ángulo respecto al origen $\hat{p}_i$ pertenece al intervalo angular $I(\hat{d}_{i,j})$ asociado a la dirección discreta $\hat{d}_{i,j}$. Esta intersección restringe el espacio posible del punto no pivote, preservando la coherencia direccional y limitando la perturbación para mantener la utilidad de la trayectoria.

Ejemplo ilustrativo. Supongamos que el espacio $\mathcal{P}$ está discretizado en una cuadrícula y que existen 8 sectores direccionales (es decir, $|\mathcal{D}| = 8$), cada uno de $\frac{\pi}{8}$ radianes. Para el punto no pivote p_j , su vecino anterior $\hat{p}_{j-1}$ le asigna una dirección perturbada $\hat{d}_{j-1,j} = 2$, mientras que su vecino posterior $\hat{p}_{j+1}$ le asigna $\hat{d}_{j+1,j} = 3$. Entonces

$$\text{Desde } \hat{p}_{j-1} : \theta_{\min}^{(1)} = \frac{3\pi}{8}, \quad \theta_{\max}^{(1)} = \frac{5\pi}{8}$$

$$\text{Desde } \hat{p}_{j+1} : \theta_{\min}^{(2)} = \frac{5\pi}{8}, \quad \theta_{\max}^{(2)} = \frac{7\pi}{8}$$

Por tanto, el dominio angular permitido para p_j está contenido entre $\frac{5\pi}{8}$ y $\frac{5\pi}{8}$, es decir, una intersección mínima (un solo borde compartido), lo que restringe significativamente su posible ubicación. Este tipo de intersección garantiza que la dirección entre p_j y sus pivotes vecinos no varíe de forma abrupta, manteniendo la consistencia espacial de la trayectoria original.

2.4.4. Selección de Granularidad Óptima

La selección de la granularidad óptima, denotada como $|\mathcal{D}|$, resulta fundamental para lograr un balance adecuado entre la precisión y la privacidad en la perturbación direccional. Este proceso se formaliza como la búsqueda de la granularidad g dentro de un conjunto de candidatos $\mathcal{D}_c$ que maximice la función objetivo definida como el promedio ponderado de la cobertura geométrica y la probabilidad de acierto sobre distintos rangos angulares de consulta. Matemáticamente, esto se expresa como

$$|\mathcal{D}|_{\text{opt}} = \arg \max_{g \in \mathcal{D}_c} \frac{1}{|\Theta|} \sum_{\theta_j \in \Theta} \sum_{d_i \in \mathcal{R}(g)} \underbrace{\varphi(d_i; \theta_j)}_{\text{Cobertura geométrica}} \times \underbrace{\lambda(d_i; \epsilon; g)}_{\text{Probabilidad de acierto}}.$$

Los conjuntos de referencia involucrados en este cálculo son: el conjunto de granularidades candidatas $\mathcal{D}_c = \{g_1, g_2, \dots, g_n\}$, que representan los posibles números de sectores angulares; el conjunto de índices de dirección para una granularidad dada, $\mathcal{R}(g) = \{0, 1, \dots, g-1\}$;

y el conjunto de rangos angulares de consulta $\Theta = \{\pi/2, \pi/4, \pi/6, \pi/12\}$, que definen diferentes amplitudes angulares de interés. A continuación, se explica las funciones de cobertura geométrica y probabilidad de acierto.

La función de cobertura geométrica $\varphi(d_i; \theta_j)$ cuantifica qué fracción del sector angular d_i está contenida dentro del rango de consulta θ_j , calculándose como la razón entre el área de intersección del sector con el rango de consulta y el área total del sector

$$\varphi(d_i; \theta_j) = \frac{|[(2d_i - 1)\frac{\pi}{g}, (2d_i + 1)\frac{\pi}{g}] \cap [-\theta_j, \theta_j]|}{2\pi/g}.$$

Ejemplo ilustrativo. Por ejemplo, para una granularidad $g = 4$ y un rango de consulta $\theta_j = \pi/4$, la cobertura geométrica para el sector $d_i = 0$ es $\varphi(0; \pi/4) = 0.5$, indicando que solo la mitad del sector está dentro del rango de interés.

La función $\lambda(d_i; \epsilon; g)$ modela la probabilidad de preservación o acierto del mecanismo de perturbación k -RR, que depende críticamente del presupuesto de privacidad ϵ . Esta función asigna mayor probabilidad a la dirección correcta y menor a las incorrectas según

$$\lambda(d_i; \epsilon; g) = \begin{cases} \frac{e^\epsilon}{g-1+e^\epsilon} & \text{si } d_i = d \text{ (dirección correcta)} \\ \frac{1}{g-1+e^\epsilon} & \text{si } d_i \neq d \text{ (dirección incorrecta)}. \end{cases}$$

Así, un mayor valor de ϵ incrementa la probabilidad de seleccionar la dirección correcta, mejorando la precisión del mecanismo. En cuanto a los criterios de diseño, una granularidad gruesa, con un valor pequeño de g , ofrece una mayor probabilidad de acierto, pero genera dominios de perturbación más amplios, lo que puede afectar la precisión espacial. Por otro lado, una granularidad fina, con un valor grande de g , permite dominios de perturbación más precisos, aunque reduce la probabilidad de preservar la dirección exacta debido a la mayor dispersión en la selección de sectores.

2.4.5. Composición Final y Análisis de Privacidad

El proceso de composición final busca optimizar la trayectoria perturbada combinando las dos versiones obtenidas mediante el mecanismo de pivotes pares e impares. Formalmente, se define una trayectoria $\hat{\tau}$ que minimiza la suma de las distancias Haversine entre cada punto candidato $\hat{p}_i$ y sus correspondientes puntos perturbados en ambas trayectorias $\hat{\tau}'$ y $\hat{\tau}^*$

$$\hat{\tau} = \arg \min_{\hat{\tau}} \sum_{i=1}^{|\tau|} (d_{\text{Hav}}(\hat{p}_i, \hat{p}_i') + d_{\text{Hav}}(\hat{p}_i, \hat{p}_i^*)).$$

Aquí, $\hat{\tau}'$ representa la trayectoria perturbada donde los puntos pares funcionan como pivotes, mientras que $\hat{\tau}^*$ corresponde a la trayectoria con pivotes en posiciones impares. El objetivo es balancear la influencia de ambas perturbaciones para obtener una representación final que reduzca el error acumulado en comparación con las trayectorias individuales. El proceso de optimización se realiza para cada punto i de la trayectoria original, generando un conjunto

de candidatos $\mathcal{P}^i$ dentro del dominio restringido definido por la intersección de dominios vecinos. Para cada candidato se calcula la suma de las distancias Haversine respecto a los puntos perturbados correspondientes en $\hat{\tau}'$ y $\hat{\tau}^*$, y se selecciona aquel que minimiza esta suma, garantizando así una mejor precisión espacial en la trayectoria final. A continuación, se presenta un pseudocódigo que ilustra este procedimiento de combinación óptima

Algorithm 1 Combinación Óptima de Trayectorias

Require: Trayectorias perturbadas $\hat{\tau}'$, $\hat{\tau}^*$, presupuesto de privacidad ϵ , dominio espacial $\mathcal{P}$

Ensure: Trayectoria final optimizada $\hat{\tau}$

```

1: Inicializar  $\hat{\tau} \leftarrow \emptyset$ 
2: for cada punto  $p_i \in \tau$  do
3:   Obtener dominio restringido por vecinos  $\mathcal{P}^i \leftarrow \{r \in \mathcal{P} \mid$ 
      $r \text{ cumple las restricciones angulares de } \hat{p}_i' \text{ y } \hat{p}_i^*\}$ 
4:   Seleccionar  $\hat{p}_i = \arg \min_{r \in \mathcal{P}^i} (d_{\text{Hav}}(r, \hat{p}_i') + d_{\text{Hav}}(r, \hat{p}_i^*))$ 
5:   Actualizar trayectoria final  $\hat{\tau} \leftarrow \hat{\tau} \cup \{\hat{p}_i\}$ 
6: end for
7: return  $\hat{\tau}$ 

```

2.4.6. Análisis de la gráfica de perturbación

La Figura 2.3 ilustra el efecto del algoritmo Pivot Sampling aplicado a una trayectoria de $N = 20$ puntos con un presupuesto de privacidad $\epsilon = 20$. Esta elección del epsilon busca mantener una relación directa entre el presupuesto de privacidad y la cantidad de perturbaciones realizadas, considerando que en el marco de la privacidad diferencial local (LDP) cada punto perturbado consume una porción del presupuesto total de privacidad. De esta manera, al asignar un ϵ proporcional al número de coordenadas publicadas, se mitiga la pérdida acumulativa de privacidad derivada de la composición aditiva, al tiempo que se preserva un nivel razonable de utilidad espacial en los datos perturbados. En la gráfica, se observa que los puntos perturbados presentan una dispersión estratégica alrededor de la trayectoria original, reflejando la naturaleza de la perturbación en dos etapas: independiente para pivotes y direccional para no pivotes. Los puntos pivote, tanto pares como impares según la copia de la trayectoria, experimentan perturbaciones independientes mediante el Mecanismo Exponencial, lo que genera desviaciones más pronunciadas respecto a sus posiciones originales. Esto se observa en la dispersión irregular de algunos puntos que se alejan significativamente de la trayectoria original. En cambio, los puntos no pivote se perturban manteniéndose dentro de restricciones angulares determinadas por sus pivotes vecinos, generando un patrón donde ciertos puntos se alinean con direcciones específicas, preservando la estructura local de la trayectoria y evitando distorsiones abruptas en la topología general. La intersección de dominios angulares provenientes de múltiples pivotes vecinos crea un efecto de “embudo” que limita el espacio de perturbación para los puntos no pivote, explicando por qué algunos permanecen relativamente cercanos a su posición original mientras que otros pueden alejarse más según la amplitud del dominio restringido permitido. El algoritmo logra un balance moderado entre privacidad y preservación de la estructura con $\epsilon = 20$. A diferencia del mecanismo de Laplace puro, donde la perturbación es **isótropa**

(es decir, el ruido se distribuye de manera uniforme en todas las direcciones alrededor del punto original), Pivot Sampling introduce asimetría en la perturbación: mayor libertad en direcciones no restringidas y mayor precisión en direcciones controladas por pivotes. El proceso final de optimización combina las dos versiones de la trayectoria, con pivotes pares e impares alternadamente, reduciendo el error acumulado. Esto se evidencia en ciertos puntos finales que se posicionan entre las dos trayectorias perturbadas, minimizando la suma de distancias Haversine respecto a ambas versiones. Los marcadores distintos (círculos y cruces) para los puntos iniciales y finales permiten identificar claramente la orientación y el orden temporal de la trayectoria, confirmando que el algoritmo respeta la secuencia de puntos sin inversiones temporales. Además, la granularidad óptima $|\mathcal{D}|$ seleccionada por el algoritmo determina la precisión con la que se dividen las direcciones: una granularidad mayor favorece precisión direccional pero reduce la probabilidad de acierto, mientras que una granularidad menor amplía los dominios de perturbación pero conserva mejor las direcciones verdaderas.




Figura 2.3: Trayectoria original y perturbada mediante Pivot Sampling con $\epsilon = 20$ y $N = 20$ puntos. Los círculos indican los puntos de inicio, mientras que las cruces marcan los puntos finales de cada trayectoria. La dispersión refleja la perturbación independiente de pivotes y la restricción direccional de puntos no pivote.

En conclusión, la gráfica demuestra cómo el algoritmo Pivot Sampling introduce un control más sofisticado de la perturbación en comparación con métodos isótropos puros, aprovechando información direccional para preservar la coherencia espacial de la trayectoria mientras mantiene garantías de privacidad diferencial local. Esta visualización permite comprender cómo el intercambio estratégico de pivotes entre dos copias de la trayectoria y la composición posterior optimizan el balance entre privacidad y utilidad, especialmente en escenarios donde la estructura temporal y espacial de la trayectoria es crítica.

2.5. Anchor-Based Pivot Sampling (ATP)

El mecanismo **Anchor-Based Pivot Sampling** (ATP) [12] es un enfoque basado en **privacidad diferencial local** (LDP) que mejora las técnicas tradicionales de muestreo con pivotes al incorporar anclajes espaciales y dominios de perturbación adaptativos. Esto permite reducir significativamente el ruido introducido en trayectorias geográficas al aplicar mecanismos de privacidad diferencial, especialmente cuando el presupuesto de privacidad ϵ es bajo. Según la *Primera Ley de la Geografía de Tobler*, "todo está relacionado con todo lo demás, pero las cosas más cercanas están más relacionadas entre sí". En el contexto de trayectorias humanas, esto implica que los puntos de una trayectoria tienden a agruparse espacialmente en regiones compactas. Sin embargo, los mecanismos tradicionales, como el *Pivot Sampling* (TP), generan perturbaciones sobre dominios muy amplios $\mathcal{P}$, lo cual conduce a una alta probabilidad de seleccionar puntos ruidos alejados del recorrido original, particularmente cuando el presupuesto de privacidad ϵ es pequeño. Para mitigar este problema, ATP restringe adaptativamente el dominio de perturbación a una región circular centrada en un *pivote ancla*, calculado para cada trayectoria individual. Este enfoque permite preservar la utilidad geográfica de los datos al tiempo que se mantiene el cumplimiento del modelo de privacidad diferencial.

2.5.1. Cálculo del Anclaje

Sea $\tau = \{p_1, p_2, \dots, p_n\}$ una trayectoria compuesta por coordenadas geográficas. Se define un *anclaje* α como el promedio de todas las posiciones

$$\alpha = \left(\frac{\sum_{i=1}^n \text{lat}(p_i)}{n}, \frac{\sum_{i=1}^n \text{lon}(p_i)}{n} \right). \quad (2.5)$$

Este punto α no necesariamente pertenece al conjunto discreto de ubicaciones posibles $\mathcal{P}$. Por ello, se selecciona como *pivote ancla* p_α el punto más cercano a α en $\mathcal{P}$, empleando como métrica la distancia geodésica (por ejemplo, la distancia de Haversine)

$$p_\alpha = \arg \min_{p \in \mathcal{P}} \text{dist}(\alpha, p). \quad (2.6)$$

El pivote ancla p_α se perturba para garantizar privacidad diferencial mediante el **Mecanismo Exponencial** (EM). Dicho mecanismo selecciona una ubicación $\hat{p}_\alpha \in \mathcal{P}$ con probabilidad

$$\Pr[\hat{p}_\alpha = p] = \frac{\exp\left(\frac{\epsilon \times u(p_\alpha, p)}{2\Delta u}\right)}{\sum_{p' \in \mathcal{P}} \exp\left(\frac{\epsilon \times u(p_\alpha, p')}{2\Delta u}\right)}, \quad (2.7)$$

donde la función de utilidad favorece puntos cercanos

$$u(p_\alpha, p) = -\text{dist}(p_\alpha, p) \quad (2.8)$$

y la sensibilidad Δu se calcula como

$$\Delta u = \max_{p, p' \in \mathcal{P}} |\text{dist}(p_\alpha, p') - \text{dist}(p_\alpha, p)|. \quad (2.9)$$

Un ϵ alto concentra la probabilidad en puntos próximos a p_α , mientras que un ϵ bajo produce una distribución más uniforme.

Ejemplo ilustrativo. Supongamos que la trayectoria es $\tau = \{p_1, p_2, p_3\}$ con coordenadas simplificadas

$$p_1 = (1.00, 1.00), \quad p_2 = (1.02, 1.03), \quad p_3 = (0.98, 1.05).$$

El anclaje se calcula como el promedio

$$\alpha = \left(\frac{1.00+1.02+0.98}{3}, \frac{1.00+1.03+1.05}{3} \right) = (1.00, 1.027).$$

Dado el conjunto de ubicaciones $\mathcal{P} = \{p_1, p_2, p_3, p_4\}$, donde $\tau \subset \mathcal{P}$ y el punto adicional $p_4 = (1.10, 0.95)$ representa una ubicación candidata fuera de la trayectoria original, se busca el punto más cercano a α dentro de $\mathcal{P}$.

La distancia mínima se obtiene para p_1 , por lo que

$$p_\alpha = p_1.$$

Ahora se aplica el Mecanismo Exponencial (EM) con $\epsilon = 1$. La utilidad está dada por $u(p_\alpha, p) = -\text{dist}(p_\alpha, p)$. Si suponemos las siguientes distancias en kilómetros

$$\text{dist}(p_\alpha, p_1) = 0, \quad \text{dist}(p_\alpha, p_2) = 3, \quad \text{dist}(p_\alpha, p_3) = 5, \quad \text{dist}(p_\alpha, p_4) = 7,$$

los pesos son

$$w(p_1) = e^0 = 1, \quad w(p_2) = e^{-1.5} \approx 0.223, \quad w(p_3) = e^{-2.5} \approx 0.082, \quad w(p_4) = e^{-3.5} \approx 0.030.$$

Normalizando,

$$\Pr[\hat{p}_\alpha = p_1] \approx 0.73, \quad \Pr[\hat{p}_\alpha = p_2] \approx 0.16, \quad \Pr[\hat{p}_\alpha = p_3] \approx 0.06, \quad \Pr[\hat{p}_\alpha = p_4] \approx 0.02.$$

Así, con alta probabilidad el ancla perturbada $\hat{p}_\alpha$ coincide con p_1 , aunque aún existe una pequeña probabilidad de seleccionar otros puntos para preservar la privacidad.

2.5.2. Dominio restringido de perturbación

Una vez obtenido el pivote perturbado $\hat{p}_\alpha$, no es eficiente aplicar los mecanismos de privacidad sobre todo el dominio global $\mathcal{P}$, ya que este puede ser demasiado amplio y disperso. En lugar de ello, el mecanismo **Anchor-Based Pivot Sampling** restringe el dominio de perturbación a una región circular centrada en $\hat{p}_\alpha$, con un radio R calibrado para cada trayectoria.

De esta forma, solo se consideran como candidatos los puntos cercanos al pivote perturbado. Formalmente, el dominio restringido se define como

$$\hat{P}_\alpha = \{p \in \mathcal{P} \mid \text{dist}(\hat{p}_\alpha, p) \leq R\}. \quad (2.10)$$

Este conjunto $\hat{P}_\alpha$ contiene todos los puntos de $\mathcal{P}$ que se encuentran dentro de la circunferencia de radio R alrededor de $\hat{p}_\alpha$. El parámetro R controla el equilibrio entre privacidad y utilidad: un valor pequeño concentra los puntos en torno a la trayectoria original (mayor utilidad, menor privacidad), mientras que un valor grande incluye más ubicaciones posibles (mayor privacidad, menor utilidad).

Ejemplo ilustrativo. Continuando con el ejemplo anterior, supongamos que el ancla perturbada es $\hat{p}_\alpha = p_1 = (1.00, 1.00)$. Sea el conjunto global $\mathcal{P} = \{p_1, p_2, p_3, p_4\}$ con las siguientes distancias (en km) respecto a $\hat{p}_\alpha$

$$\text{dist}(\hat{p}_\alpha, p_1) = 0, \quad \text{dist}(\hat{p}_\alpha, p_2) = 3, \quad \text{dist}(\hat{p}_\alpha, p_3) = 5, \quad \text{dist}(\hat{p}_\alpha, p_4) = 7.$$

Si se fija un radio $R = 4$ km, el dominio restringido queda

$$\hat{P}_\alpha = \{p \in \mathcal{P} \mid \text{dist}(\hat{p}_\alpha, p) \leq 4\} = \{p_1, p_2\}.$$

Con este valor, solo los puntos p_1 y p_2 son considerados candidatos, reduciendo la dispersión del dominio de perturbación. En contraste, si $R = 7$ km, entonces

$$\hat{P}_\alpha = \{p_1, p_2, p_3, p_4\},$$

lo cual aumenta la privacidad al precio de incluir puntos más alejados de la trayectoria original.

2.5.3. Determinación del Radio Adaptativo

Dado que diferentes usuarios generan trayectorias con áreas de cobertura muy distintas, el uso de un radio fijo R para todas ellas resulta ineficiente. Si R es demasiado pequeño, puede excluir una parte significativa de los puntos originales de la trayectoria, perdiendo utilidad. Por el contrario, si R es demasiado grande, se incorporan numerosos puntos ruidosos en el conjunto candidato, degradando la precisión del mecanismo. Para mitigar este problema, se adopta una estrategia **adaptativa**, asignando un valor de R distinto a cada trayectoria en función de sus características espaciales.

Cálculo del radio máximo. Sea $\tau = \{p_1, p_2, \dots, p_n\}$ una trayectoria, y $\hat{p}_\alpha$ el pivote ancla perturbado. Se define el radio máximo asociado a τ como la mayor distancia entre $\hat{p}_\alpha$ y un punto de la trayectoria

$$R_\tau^{\max} = \max_{p \in P_\tau} \text{dist}(\hat{p}_\alpha, p), \quad (2.11)$$

donde $P_\tau \subseteq \mathcal{P}$ denota el conjunto de puntos que conforman la trayectoria. Este valor garantiza que todos los puntos de la trayectoria se encuentren dentro de la región circular de radio $R_\tau^{\max}$ centrada en $\hat{p}_\alpha$.

Perturbación del radio. Para preservar la privacidad, $R_\tau^{\max}$ no se utiliza directamente, sino que debe ser perturbado. Dado que se trata de una cantidad acotada, se aplica el **Square-Wave Mechanism** (SW) [12], el cual está diseñado para manejar datos continuos dentro de un rango finito. Primero, se normaliza el radio con respecto al valor máximo posible

$$r = \frac{R_\tau^{\max}}{\Delta R}, \quad \text{donde } \Delta R = \max_{p \in \mathcal{P}} \text{dist}(\hat{p}_\alpha, p).$$

Luego, r se perturba mediante el mecanismo SW para obtener $\hat{r}$. Finalmente, el valor perturbado se reescala al dominio real de distancias

$$\hat{R}_\tau^{\max} = \frac{(\hat{r} + b) \Delta R}{2b + 1}. \quad (2.12)$$

Formalmente, el mecanismo SW M satisface ϵ -LDP si, para cualquier entrada $x \in [0, 1]$ y salida $y \in [-b, b + 1]$, la probabilidad de salida está dada por

$$\Pr[M(x) = y] = \begin{cases} \frac{e^\epsilon}{2be^\epsilon + 1}, & \text{si } |x - y| \leq b, \\ \frac{1}{2be^\epsilon + 1}, & \text{en otro caso.} \end{cases}$$

donde

$$b = \frac{\epsilon e^\epsilon - e^\epsilon + 1}{2e^\epsilon(e^\epsilon - 1 - \epsilon)}.$$

El uso del SW puede provocar que, bajo valores pequeños de ϵ , el radio perturbado sea excesivamente pequeño o grande debido al alto nivel de aleatoriedad. No obstante, al considerar que el tamaño de las regiones de movilidad humana sigue aproximadamente una distribución tipo *power-law* [13], la ocurrencia de radios muy grandes es poco frecuente. Además, incluso si $\hat{R}_\tau^{\max}$ resulta mayor al radio original, esto puede ser beneficioso: la región ampliada logra cubrir con mayor probabilidad los puntos reales de la trayectoria, manteniendo así la utilidad, mientras que el incremento de ruido es moderado en comparación con el tamaño total del espacio. Por esta razón, se emplea una **calibración adicional** que ajusta los radios perturbados hacia un valor “central” cuando ϵ es pequeño, reduciendo los efectos de la variabilidad extrema.

Ejemplo ilustrativo. Consideremos nuevamente la trayectoria $\tau = \{p_1, p_2, p_3\}$ con

$$p_1 = (1.00, 1.00), \quad p_2 = (1.02, 1.03), \quad p_3 = (0.98, 1.05).$$

Supongamos que el ancla perturbada es $\hat{p}_\alpha = p_1$. 1) *Cálculo del radio máximo*. Las distancias de $\hat{p}_\alpha$ a los puntos de la trayectoria son

$$\text{dist}(p_1, p_1) = 0, \quad \text{dist}(p_1, p_2) = 3 \text{ km}, \quad \text{dist}(p_1, p_3) = 5 \text{ km}.$$

Por tanto,

$$R_\tau^{\max} = \max\{0, 3, 5\} = 5 \text{ km}.$$

2) *Normalización*. Si la distancia máxima en el dominio es

$$\Delta R = \max_{p \in \mathcal{P}} \text{dist}(\hat{p}_\alpha, p) = 7 \text{ km},$$

entonces

$$r = \frac{R_\tau^{\max}}{\Delta R} = \frac{5}{7} \approx 0.714.$$

3) *Perturbación con SW*. Sea $\epsilon = 1$. El parámetro b se calcula como

$$b = \frac{\epsilon e^\epsilon - e^\epsilon + 1}{2e^\epsilon(e^\epsilon - 1 - \epsilon)} = \frac{1 \times e - e + 1}{2e(e - 2)}.$$

Con $e \approx 2.718$, se obtiene

$$b \approx \frac{0.718}{2 \times 2.718 \times 0.718} \approx 0.184.$$

Suponiendo que el mecanismo SW devuelve un valor perturbado $\hat{r} = 0.60$, el radio se reescala a

$$\hat{R}_\tau^{\max} = \frac{(\hat{r} + b) \Delta R}{2b + 1} = \frac{(0.60 + 0.184) \times 7}{1.368} \approx 4.01 \text{ km}.$$

Interpretación. Aunque el radio real máximo era de 5 km, el mecanismo SW produce un valor perturbado de ≈ 4 km. De esta forma, se conserva la mayor parte de la utilidad (la región sigue cubriendo casi todos los puntos de la trayectoria), mientras que se introduce aleatoriedad suficiente para garantizar privacidad diferencial.

2.5.4. Calibración del Radio

La calibración del radio consta de dos pasos principales (i) determinar el *centro de calibración* y (ii) calcular el tamaño del paso de ajuste en función de ϵ y calibrar el radio. Recordemos que $R_\tau^{\max}$ está acotado y corresponde a la distancia más lejana entre el punto ancla perturbado $\hat{p}_\alpha$ y los puntos de la trayectoria. Para identificar un valor adecuado η como centro de calibración, se busca amplificar el impacto de los puntos que satisfacen un rango posible de distancias máximas desde $\hat{p}_\alpha$. Dado que el dominio de entrada del mecanismo SW es $[0, 1]$, se generan valores de prueba de manera uniforme para evitar fugas de privacidad y calcular los posibles rangos. Sea

$$V = \{v_k \mid v_k = 0.1 \times k, \ k = 0, 1, \dots, 10\}$$

el conjunto de valores de prueba, y se definen

$$l_k = v_k - b, \quad u_k = v_k + b.$$

De este modo, el conjunto de valores relevantes V_R se determina como

$$V_R = \left\{ v_k \in V \mid l_k \leq \frac{(2b+1)\hat{R}_\tau^{\max}}{\Delta R} - b \leq u_k, \quad 0 \leq k \leq 10 \right\}.$$

A partir de ello, se obtiene el rango inferior y superior

$$l = \min_{v_k \in V_R} v_k, \quad u = \max_{v_k \in V_R} v_k.$$

El conjunto de puntos candidatos se define como

$$P^R = \left\{ p \in P \mid l \leq \frac{(2b+1) \text{dist}(\hat{p}_\alpha, p)}{\Delta R} - b \leq u \right\}.$$

Los valores en V se utilizan únicamente como pruebas. Para cada v_k , se calcula la probabilidad

$$q = \frac{e^\epsilon}{2be^\epsilon + 1},$$

la cual representa la fracción de masa probabilística concentrada en el rango de salida más probable del mecanismo SW. Finalmente, el **centro de calibración** η se calcula como el promedio ponderado de las distancias, asignando mayor peso a los puntos candidatos

$$\eta = \frac{\sum_{p \in P^R} q \times \text{dist}(\hat{p}_\alpha, p) + \sum_{p' \in P - P^R} (1 - q) \times \text{dist}(\hat{p}_\alpha, p')}{q|P^R| + (1 - q)|P - P^R|}.$$

Ejemplo ilustrativo. Siguiendo con el caso anterior, supongamos que el radio perturbado calculado fue

$$\hat{R}_\tau^{\max} = 4.01 \text{ km}, \quad \Delta R = 7 \text{ km}, \quad \epsilon = 1,$$

y recordemos que el parámetro del mecanismo SW era $b \approx 0.184$. 1) *Determinación de los valores relevantes.* El factor de normalización es

$$z = \frac{(2b+1)\hat{R}_\tau^{\max}}{\Delta R} - b = \frac{1.368 \times 4.01}{7} - 0.184 \approx 0.598.$$

Sea $V = \{0, 0.1, 0.2, \dots, 1.0\}$. Para $v_6 = 0.6$, se cumple que

$$l_6 = 0.6 - 0.184 = 0.416, \quad u_6 = 0.6 + 0.184 = 0.784,$$

y efectivamente $z = 0.598 \in [0.416, 0.784]$. Por lo tanto, $V_R = \{0.6\}$ y se obtiene $l = u = 0.6$.

2) *Conjunto candidato.* El conjunto P^R incluye aquellos puntos $p \in P$ que cumplen

$$l \leq \frac{(2b+1) \text{dist}(\hat{p}_\alpha, p)}{\Delta R} - b \leq u.$$

En este caso, al evaluar las distancias respecto a $\hat{p}_\alpha = p_1$, se encuentra que p_2 (3 km) y p_3 (5 km) caen dentro del rango permitido, por lo que

$$P^R = \{p_2, p_3\}.$$

3) *Cálculo del centro de calibración.* El peso del mecanismo SW es

$$q = \frac{e^\epsilon}{2be^\epsilon + 1} = \frac{2.718}{2 \times 0.184 \times 2.718 + 1} \approx 0.881. \quad (2.13)$$

Aplicando la fórmula para el centro de calibración

$$\eta = \frac{q \times (\text{dist}(p_1, p_2) + \text{dist}(p_1, p_3)) + (1 - q) \times \text{dist}(p_1, p_4)}{q|P^R| + (1 - q)|P - P^R|}. \quad (2.14)$$

Sustituyendo los valores numéricos

$$\eta = \frac{0.881 \times (3 + 5) + 0.119 \times 7}{0.881 \times 2 + 0.119 \times 1} = \frac{7.048 + 0.833}{1.762 + 0.119} = \frac{7.881}{1.881} \approx 4.19 \text{ km.}$$

Interpretación. El centro de calibración $\eta \approx 4.19$ km ajusta el valor perturbado del radio hacia una zona central, suavizando la variabilidad introducida por el mecanismo SW y manteniendo un compromiso entre privacidad y utilidad.

2.5.5. Ajuste del Radio Perturbado

Una vez obtenido el centro de calibración η , el siguiente paso consiste en determinar cómo “atraer” el radio perturbado $\hat{R}_\tau^{\max}$ hacia dicho centro. Por la propiedad del mecanismo SW, el valor perturbado se concentra más conforme el presupuesto de privacidad ϵ aumenta. Por lo tanto, el efecto de la calibración debe reducirse a medida que ϵ crece. El radio calibrado se define como

$$\hat{R} = \hat{R}_\tau^{\max} + \xi e^{-\epsilon}, \quad (2.15)$$

donde el término de calibración está compuesto por dos factores (i) el *factor de decaimiento* $e^{-\epsilon}$, que controla el efecto de la calibración reduciéndolo cuando ϵ es mayor, y (ii) el *factor de desplazamiento* ξ , que depende de la diferencia entre el radio perturbado y el centro de calibración. El factor de desplazamiento se define como

$$\xi = (\eta - \hat{R}_\tau^{\max}) \times \frac{1}{1 - e^{-\beta/2}}, \quad (2.16)$$

donde el signo de ξ indica la dirección de ajuste: será positivo si el radio perturbado es menor que η , y negativo si es mayor. De esta forma, el valor de ξ no se convierte en una constante ni en un valor extremo. Finalmente, para normalizar la diferencia entre el radio perturbado y

η en el rango $[0, 1]$, se introduce el parámetro β , definido como

$$\beta = \begin{cases} \frac{\eta - \hat{R}_\tau^{\max}}{\eta}, & \text{si } \hat{R}_\tau^{\max} \leq \eta, \\ \frac{\hat{R}_\tau^{\max} - \eta}{\Delta R - \eta}, & \text{en caso contrario.} \end{cases} \quad (2.17)$$

Posteriormente, $\beta/2$ es utilizado como entrada de una función de activación *sigmoide*, la cual se define como

$$\sigma(x) = \frac{1}{1 + e^{-x}},$$

introduciendo una propiedad no lineal y evitando que el paso de movimiento tome exactamente el valor $|\eta - \hat{R}_\tau^{\max}|$. En este caso, la entrada es $x = \beta/2$, por lo que la sigmoide aplicada es

$$\sigma\left(\frac{\beta}{2}\right) = \frac{1}{1 + e^{-\beta/2}}.$$

Gracias a este proceso de calibración, el radio perturbado se ajusta de manera controlada, y se obtiene finalmente el conjunto de puntos perturbados de la trayectoria de entrada.

Ejemplo ilustrativo. Supongamos que, tras la perturbación y calibración intermedia, se obtuvo

$$\hat{R}_\tau^{\max} = 4.01 \text{ km}, \quad \eta = 4.19 \text{ km}, \quad \Delta R = 7 \text{ km}.$$

1) *Cálculo de β .* Como $\hat{R}_\tau^{\max} \leq \eta$, se aplica la primera definición

$$\beta = \frac{\eta - \hat{R}_\tau^{\max}}{\eta} = \frac{4.19 - 4.01}{4.19} \approx 0.043.$$

2) *Cálculo del factor de desplazamiento ξ .*

$$\xi = (\eta - \hat{R}_\tau^{\max}) \times \frac{1}{1 - e^{-\beta/2}}.$$

Evaluando

$$\eta - \hat{R}_\tau^{\max} = 0.18, \quad \beta/2 \approx 0.0215, \quad e^{-\beta/2} \approx 0.979.$$

Por lo tanto

$$\xi = 0.18 \times \frac{1}{1 - 0.979} = 0.18 \times \frac{1}{0.021} \approx 8.57.$$

3) *Cálculo del radio calibrado.* Para distintos valores de ϵ , el efecto del decaimiento $e^{-\epsilon}$ será

$$\hat{R} = \hat{R}_\tau^{\max} + \xi e^{-\epsilon}.$$

- Si $\epsilon = 0.5$

$$\hat{R} = 4.01 + 8.57 \times e^{-0.5} \approx 4.01 + 5.20 = 9.21 \text{ km}.$$

- Si $\epsilon = 1$

$$\hat{R} = 4.01 + 8.57 \times e^{-1} \approx 4.01 + 3.15 = 7.16 \text{ km.}$$

- Si $\epsilon = 2$

$$\hat{R} = 4.01 + 8.57 \times e^{-2} \approx 4.01 + 1.16 = 5.17 \text{ km.}$$

Interpretación. Cuando ϵ es pequeño, el efecto de calibración es fuerte y el radio se expande significativamente (privacidad más alta, menor utilidad). A medida que ϵ crece, el término $e^{-\epsilon}$ decae y el radio calibrado se aproxima a $\hat{R}_\tau^{\max}$, preservando mejor la utilidad.

2.5.6. Análisis de la gráfica de perturbación

La Figura 2.4 muestra el efecto del mecanismo *Anchor-based Pivot Sampling* (ATP) aplicado a una trayectoria diagonal de $N = 20$ puntos con un presupuesto de privacidad $\epsilon = 20$. Este mecanismo combina principios de anclaje direccional y pivotes restringidos para controlar la dispersión del ruido en función de la estructura local de la trayectoria. A diferencia de los mecanismos puramente isotrópicos, ATP introduce un sesgo direccional que favorece la preservación de la forma global y la continuidad espacial de los segmentos entre puntos adyacentes. En la gráfica se observa que los puntos perturbados (línea roja) mantienen una tendencia general próxima a la trayectoria original (línea azul), aunque con desviaciones notables en regiones intermedias donde la trayectoria presenta menor densidad de anclajes efectivos. El uso de $\epsilon = 20$ implica un nivel de privacidad relativamente bajo, lo que se traduce en una dispersión acotada del ruido. Sin embargo, el mecanismo mantiene la independencia local de las perturbaciones y, al mismo tiempo, evita distorsiones extremas gracias a las restricciones geométricas impuestas por los pivotes. Esto se refleja en el hecho de que, a pesar de las desviaciones laterales, la secuencia temporal de los puntos se conserva sin inversiones, y la dirección general de avance de la trayectoria diagonal permanece reconocible. Los marcadores iniciales y finales (círculos y cruces) permiten identificar la orientación de ambas trayectorias, mostrando que ATP conserva la coherencia topológica y respeta la estructura temporal del movimiento. A diferencia del mecanismo de Laplace, donde la dispersión es **isotrópica** —es decir, el ruido se distribuye uniformemente en todas las direcciones alrededor del punto original—, el ATP aplica una perturbación **anisotrópica**, en la cual la magnitud y dirección del ruido dependen del contexto geométrico y de los pivotes de referencia. Esta característica permite orientar la perturbación en direcciones menos sensibles y limitarla en aquellas que afectan la coherencia espacial.




Figura 2.4: Trayectoria original y perturbada mediante el mecanismo ATP con $\epsilon = 20$ y $N = 20$ puntos. Los círculos indican los puntos iniciales y las cruces los puntos finales de cada trayectoria.

En conclusión, la gráfica evidencia que el mecanismo ATP logra un equilibrio eficaz entre privacidad y utilidad, preservando la forma global de la trayectoria mientras introduce ruido localizado que protege las posiciones individuales. La perturbación anisotrópica guiada por anclas permite mantener continuidad espacial y coherencia direccional, ofreciendo una mejora significativa respecto a los métodos de perturbación puramente aleatorios.

Capítulo 3

Análisis del Comportamiento del Presupuesto de Privacidad

Como se explicó en la Sección 2.1, los mecanismos de *privacidad diferencial central* (CDP) y *privacidad diferencial local* (LDP) difieren en la manera en que gestionan el presupuesto de privacidad ϵ . En esta sección, se profundiza en el papel de dicho parámetro dentro del contexto experimental, destacando cómo su configuración afecta la utilidad y el nivel de ruido en las trayectorias perturbadas.

El presupuesto de privacidad ϵ es un parámetro fundamental en los mecanismos de privacidad diferencial que determina el nivel de protección ofrecido a los individuos. Como se mencionó previamente, valores pequeños de ϵ garantizan mayor privacidad mediante la adición de ruido significativo, mientras que valores grandes permiten mayor precisión en los datos perturbados al costo de reducir la privacidad. Este parámetro no es estático y su comportamiento varía según el enfoque de privacidad empleado.

En particular, los algoritmos basados en **privacidad diferencial local** (LDP), como Pivot Sampling y LDPTrace, requieren que el presupuesto de privacidad se distribuya entre todos los puntos de la trayectoria [9]. Esto significa que ϵ debe ajustarse de acuerdo con la cantidad de puntos N en la trayectoria, ya que cada punto consume parte del presupuesto global. Formalmente, en LDP, cuando múltiples puntos participan en el proceso de perturbación, el presupuesto total se fracciona o se aplica mediante mecanismos de composición, afectando la relación entre ϵ y el nivel de ruido introducido.

Contrariamente, el **Mecanismo de Laplace** implementa **privacidad diferencial central** (CDP), donde existe un curador de confianza que tiene acceso a todos los datos. En este escenario, el presupuesto de privacidad ϵ es global y no depende del número de puntos N en la trayectoria. El parámetro ϵ se aplica uniformemente a cada punto, sin necesidad de composición, permitiendo una aplicación más directa y homogénea del ruido Laplace.

3.1. Metodología de Análisis del Presupuesto de Privacidad ϵ

Para comprender el comportamiento de estos algoritmos y cuantificar el *trade-off* entre privacidad y utilidad, se realiza un análisis comparativo utilizando una trayectoria real de Pekín (Beijing) que contiene $N = 908$ puntos. Esta trayectoria de dimensionalidad significativa permite observar cómo los distintos mecanismos se comportan frente a datos reales de alta dimensionalidad.

3.1.1. Métricas de Evaluación

El análisis se realiza mediante las siguientes métricas:

Tabla 3.1: Métricas utilizadas para evaluar las trayectorias perturbadas.

Métrica	Descripción
Distancia Media (Mean Distance)	Promedio de las distancias Haversine entre puntos originales y sus correspondientes versiones perturbadas. Cuantifica el desplazamiento promedio introducido por el mecanismo.
Distancia Máxima (Maximum Distance)	Máximo desplazamiento observado entre cualquier par de puntos originales y perturbados. Indica el peor caso de perturbación.
Desviación Estándar (Standard Deviation)	Medida de la variabilidad en los desplazamientos. Una desviación alta indica perturbaciones inconsistentes.
Error de Longitud (Length Error)	Diferencia entre la longitud total de la trayectoria original y la perturbada, calculada como la suma de distancias Haversine entre puntos consecutivos.
Error de Dirección (Directional Error)	Medida del cambio en la dirección general de movimiento entre la trayectoria original y perturbada, basado en el ángulo entre vectores sucesivos.
Tiempo de Procesamiento (Processing Time)	Tiempo total requerido para ejecutar el algoritmo de perturbación sobre la trayectoria. Indicador de eficiencia computacional.

3.1.2. Conjunto de Datos

Para el análisis se utilizó una trayectoria real de la ciudad de Pekín (Beijing) proveniente del **conjunto de datos de trayectorias GPS Microsoft Geolife** [14, 15, 16].

Este conjunto, recopilado por *Microsoft Research*, contiene más de 17.000 trayectorias registradas por 178 usuarios entre 2007 y 2011, representando patrones reales de movilidad urbana. La trayectoria seleccionada incluye $N = 908$ puntos con variabilidad espacial y temporal, adecuada para evaluar el desempeño de los mecanismos de perturbación en datos reales de alta resolución.

3.1.3. Normalización de Epsilon a Escala Unificada

Dado que los algoritmos emplean diferentes interpretaciones del presupuesto de privacidad ϵ y pueden requerir valores numéricos significativamente distintos para lograr niveles de privacidad comparables, es necesario normalizar los valores de ϵ a una escala común para facilitar la comparación. Se establece una escala unificada de 1 a 5, donde:

Tabla 3.2: Escala unificada de normalización del presupuesto de privacidad ϵ .

Nivel	Interpretación
1	Máxima privacidad (mínima utilidad)
2	Privacidad alta (utilidad baja)
3	Balance moderado entre privacidad y utilidad
4	Privacidad baja (utilidad alta)
5	Mínima privacidad (máxima utilidad)

Esta normalización permite realizar comparaciones justas entre los tres algoritmos, compensando las diferencias inherentes en cómo cada uno interpreta y aplica el presupuesto de privacidad. El mapeo específico de valores de ϵ originales a esta escala unificada se describe individualmente para cada algoritmo en las secciones subsecuentes. A continuación, se presenta un análisis detallado del comportamiento de cada algoritmo de perturbación bajo diferentes niveles de la escala unificada de privacidad, utilizando la trayectoria real de Pekín con $N = 908$ puntos como base de evaluación. Para cada algoritmo se especificará el mapeo de sus parámetros originales a la escala de 1 a 5, así como los resultados obtenidos en términos de las métricas de evaluación descritas anteriormente.

3.2. Mecanismo de Laplace

Como se mencionó en la introducción del capítulo, la escala unificada de privacidad (1 a 5) se estableció para facilitar comparaciones justas entre algoritmos. Sin embargo, el Mecanismo de Laplace presenta un desafío particular: no puede utilizar directamente los valores de ϵ especificados en esa escala porque sus parámetros dependen críticamente de la escala numérica de las coordenadas de entrada.

Dado que en este análisis se trabaja con coordenadas geográficas reales (latitud y longitud) convertidas a un sistema métrico local, es imprescindible realizar un ajuste específico del presupuesto de privacidad. Este ajuste se realiza a través del concepto de **radio medio de perturbación deseado** en metros, que es una magnitud física interpretable. A partir de este radio deseado, se calcula el parámetro ϵ específico que debe ser utilizado para el Mecanismo de Laplace.

Las subsecciones siguientes detallan cómo se realiza este ajuste y por qué es necesario para garantizar que el comportamiento del Mecanismo de Laplace sea comparable al de los otros algoritmos en la escala unificada.

3.2.1. Importancia de la Escala de Coordenadas

El Mecanismo de Laplace es agnóstico respecto a las **unidades físicas** de entrada (metros, kilómetros, grados, etc.), pero su comportamiento depende críticamente de la **escala numérica** en la que se expresan las coordenadas. Esta distinción es fundamental y explica por qué es necesario ajustar el parámetro ϵ incluso después de convertir coordenadas geográficas a un sistema métrico local. La relación que gobierna el mecanismo de Laplace en 2D es $E[r] = \frac{2}{\epsilon}$.

donde $E[r]$ es la distancia media esperada de desplazamiento y ϵ es el parámetro de privacidad. Esta fórmula es exacta y no depende de unidades, pero su interpretación práctica sí depende de la escala de las coordenadas de entrada.

Problema en escala pequeña (grados lat/lon). Si se aplica Laplace directamente sobre coordenadas geográficas en grados:

- Rango típico de coordenadas: 0 a 180 grados
- Si se usa $\epsilon = 0.01$ (valor arbitrario pequeño):

$$E[r] = \frac{2}{0.01} = 200 \text{ grados} \quad (3.1)$$

- Interpretación: el ruido medio es 200 grados, equivalente a aproximadamente 22,200 km
- Resultado: la perturbación es completamente desproporcionada y no controlable

El problema no es del mecanismo, sino de la escala: un ϵ pequeño produce perturbaciones grandes en la unidad elegida, lo que es sensato cuando la escala es grande (metros) pero absurdo cuando es pequeña (grados).

Solución: Proyección a coordenadas locales en metros. Mediante proyección equirectangular del primer punto de la trayectoria como referencia, se convierten las coordenadas lat/lon a un sistema local (x, y) expresado en metros:

$$x = (\lambda - \lambda_0) \times \cos(\varphi_0) \times R, \quad y = (\varphi - \varphi_0) \times R, \quad (3.2)$$

donde $R \approx 6,371,000$ m es el radio terrestre. Después de esta conversión:

- Rango típico de coordenadas: 0 a 100,000 metros (depende de la extensión de la trayectoria)
- Con el mismo $\epsilon = 0.01$:

$$E[r] = \frac{2}{0.01} = 200 \text{ metros} \quad (3.3)$$

- Interpretación: el ruido medio es 200 metros (realista y controlable)
- Resultado: la perturbación es proporcional a la escala de los datos

Conclusión clave: El mismo valor de ϵ produce resultados completamente distintos porque la escala de las coordenadas cambió. Por lo tanto, ϵ debe ser seleccionado de acuerdo a la escala numérica específica de los datos.

3.2.2. Selección de Parámetros de Privacidad mediante Radio Medio Deseado

En lugar de elegir ϵ de forma arbitraria, es más interpretable especificar directamente el **radio medio de perturbación deseado** en metros y calcular el ϵ correspondiente. La relación inversa es:

$$\epsilon = \frac{2}{\text{Radio Medio Deseado (m)}}.$$

Para este análisis, se establecieron cinco niveles de privacidad basados en comparaciones con los resultados de Pivot Sampling y LDPTrace. Los radios medios deseados en metros fueron: Los valores de ϵ se calcularon automáticamente usando la fórmula $\epsilon = \frac{2}{r_{\text{medio}}}$:

Tabla 3.3: Mapeo de niveles de privacidad del Mecanismo de Laplace: radio medio deseado, valores de ϵ calculados, y escala unificada.

Nivel	Radio Medio Deseado (m)	$\epsilon = 2/r_{\text{medio}}$	Interpretación
1	158.0	0.01264	Máxima privacidad
2	93.5	0.02148	Privacidad alta
3	65.9	0.03032	Balance moderado
4	51.1	0.03916	Privacidad baja
5	45.9	0.04358	Mínima privacidad

3.2.3. Evaluación de Métricas

A continuación se presentan los resultados del Mecanismo de Laplace aplicado a la trayectoria real de Pekín con $N = 908$ puntos, evaluados mediante las siete métricas descritas en la introducción del capítulo.




Figura 3.1: Métricas de error y desempeño del Mecanismo de Laplace bajo distintos valores de ϵ .

Distancia Media. La distancia media entre puntos originales y perturbados exhibe una relación inversamente proporcional con ϵ . Como se esperaba teóricamente, con $\epsilon = 0.01264$ (nivel 1) se obtiene una distancia media de 241.78 metros, mientras que con $\epsilon = 0.04358$ (nivel 5) disminuye a 41.40 metros. Esta tendencia decreciente es consistente con la fórmula $E[r] = \frac{1}{\epsilon}$, aunque los valores observados son superiores a lo esperado teóricamente (79.1 m y 23.0 m respectivamente), lo que indica la presencia de variabilidad inherente a la naturaleza estocástica del mecanismo.

Distancia Máxima. La distancia máxima presenta una variabilidad significativamente mayor que la distancia media, oscilando entre 1122.55 metros en el nivel 1 y 192.24 metros en el nivel 5. Esta métrica ilustra que aunque el ruido promedio es controlado, existen puntos individuales que experimentan perturbaciones extremas, lo cual es característico de la distribución exponencial del mecanismo de Laplace. La proporción entre distancia máxima y media es aproximadamente 4.7 en el nivel 1 y 4.6 en el nivel 5, mostrando consistencia en este comportamiento de cola.

Desviación Estándar. La desviación estándar del desplazamiento radial sigue una tendencia similar a la distancia media, disminuyendo de 169.43 metros (nivel 1) a 29.02 metros (nivel 5). La relación entre desviación estándar y distancia media se mantiene aproximadamente constante (≈ 0.70), confirmando la homogeneidad del patrón de perturbación a través de diferentes niveles de privacidad.

Error de Longitud. El error de longitud es la métrica que experimenta la mayor variabilidad, partiendo desde 308,809.52 metros en el nivel 1 y reduciéndose a 45,580.41 metros en el nivel 5. Esta magnitud resulta de la acumulación de errores pequeños en cada punto a lo largo de los 908 puntos de la trayectoria. Cuando cada desplazamiento tiene ruido aleatorio e independiente, los errores de longitud tienden a acumularse cuadráticamente, explicando la alta sensibilidad de esta métrica a cambios en ϵ .

Error de Dirección. El error de dirección medido en radianes es relativamente pequeño y consistente, variando entre 1.86 radianes (nivel 1) y 1.68 radianes (nivel 5). La reducción es más moderada comparada con otras métricas, lo que sugiere que el mecanismo de Laplace, al perturbar coordenadas de forma isótropa, preserva mejor la orientación general de la trayectoria que aspectos métricos como longitud o distancias puntuales. Este comportamiento es ventajoso para aplicaciones donde la topología de la trayectoria es más importante que la precisión métrica exacta.

Tiempo de Procesamiento. El tiempo de procesamiento es extremadamente eficiente, oscilando entre 0.0108 y 0.0112 segundos para toda la trayectoria de 908 puntos. El tiempo muestra pequeñas fluctuaciones alrededor de este valor promedio sin una correlación clara con ϵ , indicando que el costo computacional es prácticamente independiente del presupuesto de privacidad. Para una trayectoria de este tamaño, el mecanismo es esencialmente instantáneo desde una perspectiva práctica.

Análisis Comparativo del Comportamiento

El Mecanismo de Laplace presenta un comportamiento altamente coherente con su fundamento teórico. En primer lugar, se confirma empíricamente la relación esperada entre el parámetro de privacidad y la magnitud del desplazamiento medio, expresada como $E[r] = \frac{1}{\epsilon}$. Aunque se observan variaciones debidas a la naturaleza estocástica del proceso de muestreo,

la tendencia general demuestra una predictibilidad teórica consistente que permite anticipar el impacto de diferentes configuraciones de privacidad.

En cuanto al compromiso entre privacidad y utilidad, los resultados muestran una correspondencia monotónica entre el incremento de ϵ y la disminución de las métricas de error. Este comportamiento evidencia un *trade-off* claro y estable, lo que facilita la calibración del mecanismo según las necesidades de privacidad del análisis. De esta forma, un aumento del presupuesto de privacidad produce una reducción proporcional del ruido, permitiendo obtener trayectorias con mayor fidelidad espacial.

Asimismo, la perturbación generada por el mecanismo es isotrópica, es decir, se distribuye de manera uniforme en todas las direcciones. Esta característica favorece la preservación de la estructura direccional de las trayectorias, manteniendo la coherencia topológica general aunque se altere la precisión métrica. Gracias a esta propiedad, el Mecanismo de Laplace logra mantener trayectorias con formas y orientaciones similares a las originales, incluso bajo niveles altos de perturbación.

Otro aspecto relevante es la acumulación de errores en métricas agregadas, como la longitud total de la trayectoria. Dado que cada punto es perturbado de manera independiente, los errores se acumulan de forma proporcional al número de puntos, generando desviaciones más notorias en trayectorias largas. Esta característica es inherente a los mecanismos de ruido independiente y debe ser considerada al analizar datos con alta densidad espacial.

Finalmente, el desempeño computacional del Mecanismo de Laplace resulta sobresaliente. El tiempo de procesamiento se mantiene prácticamente constante, en el orden de milisegundos, independientemente del valor de ϵ o del tamaño de la trayectoria. Esta eficiencia confirma que el mecanismo es adecuado para aplicaciones a gran escala o escenarios que requieran perturbaciones en tiempo real, sin introducir sobrecarga significativa en el procesamiento.

3.3. Pivot Sampling

A diferencia del Mecanismo de Laplace, que implementa privacidad diferencial central (CDP), Pivot Sampling es un algoritmo basado en **privacidad diferencial local** (LDP). Esta distinción fundamental tiene implicaciones directas sobre cómo se interpreta y calibra el presupuesto de privacidad ϵ .

3.3.1. Composición en Privacidad Diferencial Local

En el contexto de la *privacidad diferencial local* (LDP), cada punto de una trayectoria se perturba de manera independiente, lo que implica que el presupuesto de privacidad total debe considerar la composición aditiva de todas las perturbaciones individuales. En lugar de aplicar directamente la regla $\epsilon_{\text{total}} = N \times \epsilon_{\text{point}}$, se decidió introducir un parámetro de ajuste k , que toma valores entre 1 y 5, para controlar la magnitud efectiva del presupuesto empleado. De este modo, el presupuesto de privacidad se define como:

$$\epsilon_{\text{efectivo}} = k \times N, \quad (3.4)$$

donde N representa la longitud de la trayectoria. La inclusión del parámetro k responde a la necesidad de capturar de forma más realista el efecto acumulativo de la composición sin restringir excesivamente el rango de ϵ . En la práctica, un valor fijo de ϵ por punto conduciría a una pérdida de utilidad significativa cuando N es grande, debido a que la suma aditiva del presupuesto generaría una garantía de privacidad excesivamente estricta. Al introducir k como factor de ajuste, se logra escalar el presupuesto de forma controlada, permitiendo observar cómo varía el balance entre privacidad y fidelidad de la trayectoria. Esta aproximación proporciona un marco flexible para el análisis comparativo: los distintos valores de k representan escenarios con diferentes grados de protección agregada. Así, $k = 1$ puede interpretarse como una composición conservadora (alta privacidad, menor utilidad), mientras que $k = 5$ refleja un escenario más permisivo que prioriza la precisión espacial. En síntesis, el uso del parámetro k permite gestionar la composición de privacidad en trayectorias extensas sin distorsionar de manera extrema la utilidad de los datos perturbados.

3.3.2. Mapeo de Parámetros a Escala Unificada


Para los cinco niveles de la escala unificada (1 a 5), se utilizan los siguientes valores de k :

Tabla 3.4: Mapeo de niveles de privacidad para Pivot Sampling: valores de k , ϵ efectivo calculado, y escala unificada.


Nivel	k	$\epsilon_{\text{efectivo}} = k \times N$	Interpretación
1	1	$1 \times 908 = 908$	Máxima privacidad
2	2	$2 \times 908 = 1816$	Privacidad alta
3	3	$3 \times 908 = 2724$	Balance moderado
4	4	$4 \times 908 = 3632$	Privacidad baja
5	5	$5 \times 908 = 4540$	Mínima privacidad

3.3.3. Evaluación de Métricas


A continuación se presentan los resultados del algoritmo Pivot Sampling aplicado a la trayectoria real de Pekín con $N = 908$ puntos, evaluados mediante las siete métricas descritas en la introducción del capítulo. Los valores de $\epsilon_{\text{efectivo}}$ corresponden a: nivel 1 ($\epsilon_{\text{eff}} = 908$), nivel 2 ($\epsilon_{\text{eff}} = 1816$), nivel 3 ($\epsilon_{\text{eff}} = 2724$), nivel 4 ($\epsilon_{\text{eff}} = 3632$), y nivel 5 ($\epsilon_{\text{eff}} = 4540$).



(a) Distancia Media (m) vs. Presupuesto de Privacidad Efectivo $\epsilon_{\text{eff}} = k \times N$. (b) Distancia Máxima (m) vs. Presupuesto de Privacidad Efectivo ϵ_{eff} .



(c) Desviación Estándar (m) vs. Presupuesto de Privacidad Efectivo ϵ_{eff} . (d) Error de Longitud (m) vs. Presupuesto de Privacidad Efectivo ϵ_{eff} .



(e) Error de Dirección (rad) vs. Presupuesto de Privacidad Efectivo ϵ_{eff} . (f) Tiempo de Procesamiento (s) vs. Presupuesto de Privacidad Efectivo ϵ_{eff} .

Figura 3.2: Métricas de error y desempeño del algoritmo Pivot Sampling bajo distintos valores del presupuesto de privacidad efectivo ϵ_{eff} .

Distancia Media. La distancia media entre puntos originales y perturbados exhibe una relación inversamente proporcional con $\epsilon_{\text{efectivo}}$. Con $\epsilon_{\text{eff}} = 908$ (nivel 1) se obtiene una distancia media de 253.50 metros, mientras que con $\epsilon_{\text{eff}} = 4540$ (nivel 5) disminuye a 42.79 metros. Esta tendencia es consistente con el comportamiento esperado: mayores presupuestos de privacidad (menores ϵ , o equivalentemente menores k) producen perturbaciones más grandes. La disminución es aproximadamente logarítmica, típica de mecanismos de privacidad donde el beneficio de privacidad adicional disminuye con presupuestos mayores.

Distancia Máxima. La distancia máxima varía entre 1200.01 metros en el nivel 1 y 187.84 metros en el nivel 5. Comparada con Laplace, Pivot Sampling produce máximos similares, aunque con ligeras variaciones. La proporción entre distancia máxima y media es aproximadamente 4.73 en el nivel 1 y 4.39 en el nivel 5. Esta métrica refleja que, aunque la perturbación promedio es controlada, existen puntos individuales que experimentan desviaciones significativas, característica común a ambos algoritmos pero con intensidades diferentes según el nivel de privacidad.

Desviación Estándar. La desviación estándar del desplazamiento disminuye de 185.73 metros (nivel 1) a 28.13 metros (nivel 5). La relación con la distancia media es aproximadamente 0.73 en ambos extremos, similar a la observada en Laplace (0.70). Esta consistencia sugiere que ambos algoritmos mantienen patrones de variabilidad homogéneos a través de diferentes niveles de privacidad, aunque con magnitudes ligeramente mayores en Pivot Sampling.

Error de Longitud. El error de longitud es nuevamente la métrica más sensible, oscilando entre 275, 541.29 metros en el nivel 1 y 25, 508.38 metros en el nivel 5. Aunque estos valores son similares a los de Laplace, la reducción es más pronunciada en Pivot Sampling, sugiriendo que la perturbación direccional en puntos no pivote mitiga parcialmente la acumulación de errores de longitud. La estructura de dos etapas del algoritmo (pivotes independientes + no pivotes direccionales) parece producir un balance ligeramente mejor que la perturbación isótropa pura de Laplace en términos de preservación de longitud.

Error de Dirección. El error de dirección varía entre 1.83 radianes (nivel 1) y 1.35 radianes (nivel 5), mostrando una reducción más significativa que en Laplace (donde fue de 1.86 a 1.68 radianes). Esta diferencia es notable: Pivot Sampling preserva mejor la orientación general de la trayectoria, lo cual es directo resultado de la perturbación direccional de puntos no pivote. Al mantener restricciones angulares a través de la información de pivotes vecinos, el algoritmo logra preservar mejor las direcciones de movimiento general, lo que es una ventaja clara sobre Laplace en aplicaciones donde la topología direccional es importante.

Tiempo de Procesamiento. El tiempo de procesamiento muestra variabilidad significativa, oscilando entre aproximadamente 14.62 y 29.12 segundos, con un patrón no monotónico. Esto contrasta dramáticamente con Laplace, que requiere menos de 0.012 segundos. La razón está en la complejidad computacional del algoritmo: Pivot Sampling realiza múltiples iteraciones (creación de dos copias, perturbación independiente de pivotes, perturbación direccional de no pivotes, selección de dominio de perturbación mediante intersecciones, y composición final). Adicionalmente, el tiempo aumenta en los niveles intermedios (especialmente nivel 4) debido a la complejidad creciente de los cálculos de dominios angulares y optimizaciones. Este es un trade-off importante: Pivot Sampling ofrece mejor preservación de estructura (especialmente direccional), pero a costo computacional significativo.

3.3.4. Análisis Comparativo del Comportamiento

El algoritmo *Pivot Sampling* presenta un comportamiento distintivo frente al mecanismo de Laplace debido a su estructura de perturbación en dos etapas. Mientras que Laplace aplica una perturbación isótropa uniforme en todas las direcciones, *Pivot Sampling* diferencia entre puntos pivote y no pivote: los primeros se perturban de manera independiente, y los segundos lo hacen bajo restricciones direccionales basadas en sus pivotes vecinos. Esta estrategia introduce una perturbación más estructurada que conserva mejor la coherencia espacial de la trayectoria, manteniendo la orientación general del desplazamiento incluso en niveles de alta privacidad.

En términos de la relación entre privacidad y utilidad, *Pivot Sampling* revela un equilibrio particular derivado de la composición en el modelo de *privacidad diferencial local* (LDP). Aunque el presupuesto efectivo $\epsilon_{\text{eff}} = k \times N$ resulta numéricamente mayor, el efecto práctico sobre las métricas de error es comparable al de Laplace. Esto evidencia que los mecanismos locales, al operar sobre cada punto de manera independiente, requieren calibraciones distintas para alcanzar niveles de distorsión equivalentes a los de mecanismos centrales.

Una ventaja clara del enfoque de *Pivot Sampling* radica en su capacidad para preservar la orientación direccional de las trayectorias. El error angular promedio se mantiene más bajo que en el caso del mecanismo de Laplace (1.35 frente a 1.68 radianes en el nivel 5), lo que indica una mejor conservación de la topología del movimiento. Esta propiedad es particularmente valiosa en aplicaciones donde la forma y dirección del recorrido son más relevantes que la precisión métrica absoluta, como en análisis de movilidad o patrones de transporte.

Además, el algoritmo demuestra una ligera mitigación en la acumulación de errores de longitud. La perturbación parcialmente correlacionada entre puntos no pivote reduce el crecimiento cuadrático del ruido típico en mecanismos independientes, generando trayectorias con distancias totales más cercanas al original. Este comportamiento sugiere que la estructura direccional no solo preserva orientación, sino también cierta consistencia métrica global.

Sin embargo, esta mejora en la coherencia espacial implica un costo computacional considerable. *Pivot Sampling* requiere entre 15 y 29 segundos por trayectoria, en contraste con los tiempos prácticamente instantáneos del mecanismo de Laplace (del orden de 0.01 segundos). Este incremento se debe a la complejidad del proceso, que incluye la selección de pivotes, perturbaciones condicionadas, definición de dominios angulares y composición final. Además, el tiempo de ejecución no presenta un patrón monótonico: algunos niveles intermedios de k incrementan la carga computacional debido a ajustes geométricos más exigentes en la definición de las restricciones direccionales.

En conjunto, *Pivot Sampling* se destaca como un mecanismo de *privacidad diferencial local* capaz de ofrecer una mejor preservación estructural de las trayectorias, aunque a expensas de una mayor complejidad operativa. Su diseño lo hace especialmente adecuado para entornos descentralizados, donde los usuarios perturban sus propios datos antes de compartirlos, manteniendo control sobre su privacidad de manera local y autónoma.

3.4. Anchor-Based Pivot Sampling (ATP)

A diferencia de Pivot Sampling tradicional y del Mecanismo de Laplace, **Anchor-Based Pivot Sampling (ATP)** introduce un enfoque adaptativo que restringe el dominio de perturbación mediante anclajes espaciales. Este algoritmo implementa **privacidad diferencial local (LDP)** al igual que Pivot Sampling, pero incorpora dos innovaciones fundamentales: (i) el cálculo de un **pivote ancla** perturbado que sirve como referencia espacial, y (ii) la determinación de un **radio adaptativo calibrado** que restringe el dominio de perturbación a una región circular centrada en el ancla.

3.4.1. Mapeo de Parámetros a Escala Unificada

Para los cinco niveles de la escala unificada (1 a 5), se utilizan los mismos valores de k que en Pivot Sampling:

Tabla 3.5: Mapeo de niveles de privacidad para ATP: valores de k , épsilon efectivo calculado, y escala unificada.

Nivel	k	$\epsilon_{\text{efectivo}} = k \times N$	Interpretación
1	1	$1 \times 908 = 908$	Máxima privacidad
2	2	$2 \times 908 = 1816$	Privacidad alta
3	3	$3 \times 908 = 2724$	Balance moderado
4	4	$4 \times 908 = 3632$	Privacidad baja
5	5	$5 \times 908 = 4540$	Mínima privacidad


3.4.2. Evaluación de Métricas

A continuación se presentan los resultados del algoritmo ATP aplicado a la trayectoria real de Pekín con $N = 908$ puntos, evaluados mediante las siete métricas descritas en la introducción del capítulo. Los valores de $\epsilon_{\text{efectivo}}$ corresponden a: nivel 1 ($\epsilon_{\text{eff}} = 908$), nivel 2 ($\epsilon_{\text{eff}} = 1816$), nivel 3 ($\epsilon_{\text{eff}} = 2724$), nivel 4 ($\epsilon_{\text{eff}} = 3632$), y nivel 5 ($\epsilon_{\text{eff}} = 4540$).


Distancia Media. La distancia media entre puntos originales y perturbados en ATP exhibe un comportamiento no monotónico con mínimo en $\epsilon_{\text{eff}} = 1363$ (entre niveles 1 y 2), alcanzando 172.83 metros, y máximo en $\epsilon_{\text{eff}} = 4086$ (nivel 4) con 408.49 metros. Este patrón contrasta dramáticamente con el comportamiento inversamente proporcional observado en Laplace y Pivot Sampling, revelando una característica fundamental de ATP: la **interacción no lineal entre el presupuesto de privacidad y la calibración adaptativa del radio**.

En el nivel 1 ($\epsilon_{\text{eff}} = 908$), la distancia media es 403.46 metros, superior a Pivot Sampling (253.50 m) y Laplace (241.78 m). Esto se debe al efecto del término de calibración $\xi e^{-\epsilon}$ que, con ϵ pequeño, expande significativamente el radio adaptativo $\hat{R}$, incrementando el dominio de perturbación $\hat{P}_\alpha$ más allá de lo óptimo. A medida que ϵ aumenta hacia el nivel 2, el término exponencial decae rápidamente, permitiendo que la restricción adaptativa opere efectivamente y reduciendo la distancia media a su mínimo de 172.83 metros.


Sin embargo, en niveles intermedios (3-4), la distancia media vuelve a aumentar, alcanzando valores superiores incluso al nivel 1. Este comportamiento contraintuitivo se explica por la convergencia del radio calibrado hacia valores que, aunque matemáticamente óptimos según la formulación de ATP, pueden resultar en dominios $\hat{P}_\alpha$ que incluyen puntos alejados cuando la geometría de la trayectoria es irregular. En el nivel 5 ($\epsilon_{\text{eff}} = 4540$), la distancia disminuye a 337.95 metros, aunque permanece significativamente superior a Pivot Sampling (42.79 m) y Laplace (41.40 m).



(a) Distancia Media (m) vs. Presupuesto de Privacidad Efectivo $\epsilon_{\text{eff}} = k \times N$ para ATP. (b) Distancia Máxima (m) vs. Presupuesto de Privacidad Efectivo ϵ_{eff} para ATP.



(c) Desviación Estándar (m) vs. Presupuesto de Privacidad Efectivo ϵ_{eff} para ATP. (d) Error de Longitud (m) vs. Presupuesto de Privacidad Efectivo ϵ_{eff} para ATP.



(e) Error de Dirección (rad) vs. Presupuesto de Privacidad Efectivo ϵ_{eff} para ATP. (f) Tiempo de Procesamiento (s) vs. Presupuesto de Privacidad Efectivo ϵ_{eff} para ATP.

Figura 3.3: Métricas de error y desempeño del algoritmo ATP bajo distintos valores del presupuesto de privacidad efectivo ϵ_{eff} .

Distancia Máxima. La distancia máxima en ATP presenta un patrón aún más irregular, oscilando entre 1130.36 metros (mínimo en $\epsilon_{\text{eff}} = 1363$) y 1653.00 metros (máximo en $\epsilon_{\text{eff}} = 3178$). En el nivel 1 ($\epsilon_{\text{eff}} = 908$), la distancia máxima es 1598.43 metros, comparable a Pivot Sampling (1200.01 m) pero superior a Laplace (1122.55 m). Esta métrica refleja que, a pesar de la restricción del dominio, ATP puede generar perturbaciones extremas cuando el radio calibrado es grande.

El comportamiento de la distancia máxima revela una limitación importante de ATP: la calibración adaptativa del radio, aunque efectiva para reducir la distancia media en ciertos rangos, no garantiza control uniforme sobre las perturbaciones extremas. En el nivel 4 ($\epsilon_{\text{eff}} = 3632$), donde la distancia máxima alcanza 1459.20 metros, el mecanismo parece entrar en un régimen donde la expansión del radio $\hat{R}$ debido a la geometría de la trayectoria domina sobre la restricción del dominio, generando perturbaciones más grandes que en niveles de menor presupuesto.

En el nivel 5 ($\epsilon_{\text{eff}} = 4540$), la distancia máxima es 1568.91 metros, aproximadamente 8.3 veces superior a Pivot Sampling (187.84 m) y 8.2 veces superior a Laplace (192.24 m) en el mismo nivel. Esta discrepancia indica que ATP sacrifica control sobre perturbaciones extremas en favor de optimizar la distancia media en rangos específicos de ϵ .

Desviación Estándar. La desviación estándar del desplazamiento en ATP exhibe un patrón similar a la distancia media, con mínimo de 152.52 metros en $\epsilon_{\text{eff}} = 1363$ y máximo de 244.55 metros en $\epsilon_{\text{eff}} = 454$ (nivel muy bajo, previo al nivel 1). En el nivel 1 ($\epsilon_{\text{eff}} = 908$), la desviación es 193.50 metros, superior a Pivot Sampling (185.73 m) pero inferior a su propio máximo, indicando que el algoritmo ya se encuentra en fase de reducción de variabilidad.

La relación entre desviación estándar y distancia media varía significativamente a través de los niveles: aproximadamente 0.48 en el mínimo (nivel 1-2), aumentando a 0.56 en el nivel 4. Esta variación contrasta con la relación consistente observada en Laplace (0.70) y Pivot Sampling (0.73), sugiriendo que ATP introduce heterogeneidad en el patrón de perturbación que depende fuertemente del presupuesto de privacidad.

En el nivel 5 ($\epsilon_{\text{eff}} = 4540$), la desviación estándar es 233.16 metros, aproximadamente 8.3 veces superior a Pivot Sampling (28.13 m) y 8.0 veces superior a Laplace (29.02 m). Esta discrepancia persistente en todas las métricas de dispersión indica que ATP opera en un régimen fundamentalmente distinto, donde la calibración adaptativa amplifica la variabilidad en lugar de reducirla en niveles altos de presupuesto.

Error de Longitud. El error de longitud en ATP presenta una tendencia decreciente más consistente que las métricas puntuales, partiendo desde 78,483.34 metros en $\epsilon_{\text{eff}} = 454$ (previo al nivel 1) y reduciéndose progresivamente hasta 11,285.32 metros en $\epsilon_{\text{eff}} = 4540$ (nivel 5). En el nivel 1 ($\epsilon_{\text{eff}} = 908$), el error es 44,969.42 metros, significativamente superior a Pivot Sampling (275,541.29 m) pero del mismo orden de magnitud que Laplace (308,809.52 m).

Sorprendentemente, ATP logra el error de longitud más bajo entre los tres algoritmos en el nivel 5: 11,285.32 metros comparado con 25,508.38 metros en Pivot Sampling y 45,580.41

metros en Laplace. Esta mejora del 56 % respecto a Pivot Sampling y 75 % respecto a Laplace sugiere que, a pesar de las perturbaciones puntuales grandes, la calibración adaptativa del radio preserva mejor la estructura global de longitud de la trayectoria en presupuestos altos.

El comportamiento decreciente suave del error de longitud contrasta con las fluctuaciones observadas en distancia media y máxima, indicando que ATP logra un compromiso favorable en métricas agregadas incluso cuando las métricas puntuales son subóptimas. Esto es consistente con la hipótesis de que la restricción del dominio mediante el anclaje espacial preserva correlaciones locales entre puntos consecutivos, mitigando la acumulación cuadrática de errores independientes característica de Laplace.

Error de Dirección. El error de dirección en ATP disminuye monótonicamente de 1.57 radianes en $\epsilon_{\text{eff}} = 454$ (previo al nivel 1) a 1.22 radianes en $\epsilon_{\text{eff}} = 4540$ (nivel 5). En el nivel 1 ($\epsilon_{\text{eff}} = 908$), el error es 1.47 radianes, ligeramente inferior a Laplace (1.86 rad) pero superior a Pivot Sampling (1.83 rad). Esta tendencia se invierte progresivamente: en el nivel 5, ATP logra 1.22 radianes, inferior a Laplace (1.68 rad) pero aún superior a Pivot Sampling (1.35 rad).

El comportamiento monótonico decreciente del error de dirección, junto con el error de longitud, constituye evidencia de que ATP preserva mejor las **características agregadas de forma** (estructura global de la trayectoria) que las **posiciones puntuales exactas**. La restricción del dominio mediante el anclaje espacial introduce sesgo hacia la región central de la trayectoria, lo cual favorece la preservación de direcciones generales aunque las posiciones individuales puedan desviarse significativamente.

La reducción del error direccional es más moderada que en Pivot Sampling (1.57 a 1.22 rad, reducción de 22 % en ATP vs 1.83 a 1.35 rad, reducción de 26 % en Pivot Sampling), sugiriendo que la perturbación direccional explícita de puntos no pivote en Pivot Sampling sigue siendo superior a la restricción espacial implícita de ATP para preservar orientación.

Tiempo de Procesamiento. El tiempo de procesamiento en ATP oscila entre 5.06 segundos (mínimo en múltiples niveles intermedios 2-4) y 9.72 segundos (máximo en $\epsilon_{\text{eff}} = 454$, previo al nivel 1). En el nivel 1 ($\epsilon_{\text{eff}} = 908$), el tiempo es 6.46 segundos, significativamente más rápido que Pivot Sampling (14.62 segundos) pero considerablemente más lento que Laplace (0.01 segundos).

El tiempo de procesamiento en ATP es aproximadamente 2.3-2.9 veces menor que Pivot Sampling en niveles comparables, representando una mejora sustancial en eficiencia computacional. Esta reducción se atribuye a dos factores: (i) la **restricción del dominio** $\hat{P}_\alpha$ reduce drásticamente el número de puntos candidatos que deben evaluarse durante la perturbación, y (ii) la **simplicación del mecanismo de perturbación** al eliminar la estructura de dos etapas compleja de Pivot Sampling (perturbación independiente de pivotes + perturbación direccional de no pivotes con cálculo de intersecciones angulares).

El patrón de tiempo muestra una forma de U invertida con máximo en el nivel inicial y mínimo en niveles intermedios, para luego incrementarse ligeramente en el nivel 5 (7.65 segun-

dos). Este comportamiento sugiere que presupuestos muy bajos requieren mayor número de iteraciones en la calibración del radio debido al término $e^{-\epsilon}$ grande, mientras que presupuestos muy altos pueden expandir el dominio $\hat{P}_\alpha$ incrementando el número de evaluaciones.

A pesar de la mejora respecto a Pivot Sampling, ATP sigue siendo aproximadamente 600 veces más lento que Laplace, lo cual representa una limitación significativa para aplicaciones en tiempo real. El trade-off entre eficiencia computacional y preservación de estructura de trayectoria permanece como desafío fundamental en algoritmos de LDP con restricción espacial.

3.4.3. Análisis Comparativo del Comportamiento

El algoritmo *Anchor-Based Pivot Sampling* (ATP) introduce un enfoque adaptativo que, aunque inspirado en el mecanismo Pivot Sampling, se comporta de forma marcadamente distinta frente a variaciones del presupuesto de privacidad. A diferencia de los mecanismos tradicionales, donde el aumento de ϵ tiende a reducir de manera consistente la magnitud del ruido, ATP exhibe un patrón no monotónico: la distancia media alcanza un mínimo de 172.83 m en $\epsilon_{\text{eff}} = 1363$ y posteriormente aumenta hasta 408.49 m en niveles intermedios. Este comportamiento se debe a la interacción compleja entre el término de calibración $\xi e^{-\epsilon}$ y la geometría de la trayectoria, lo cual provoca que el mecanismo opere de forma óptima solo en ciertos rangos del presupuesto, en lugar de mantener una mejora progresiva con el incremento de ϵ .

La principal innovación de ATP radica en la restricción adaptativa del dominio de perturbación mediante un anclaje espacial. El cálculo del pivote ancla p_α y la definición del dominio $\hat{P}_\alpha = \{p \in \mathcal{P} \mid \text{dist}(\hat{p}_\alpha, p) \leq \hat{R}\}$ permiten concentrar las perturbaciones en regiones compactas, siguiendo la Primera Ley de Tobler. Esta restricción espacial reduce la dispersión de puntos perturbados alrededor del recorrido original, aunque su efectividad depende del radio calibrado $\hat{R}$, que puede expandirse en exceso cuando ϵ es bajo o la trayectoria presenta geometría irregular.

El proceso de calibración adaptativa basado en la geometría de la trayectoria confiere a ATP una flexibilidad significativa. El parámetro η , calculado mediante un promedio ponderado de distancias en el conjunto candidato P^R , ajusta automáticamente el comportamiento del algoritmo según la estructura espacial de los datos. Esto permite que ATP se adapte a trayectorias compactas y uniformes, mejorando su rendimiento sin necesidad de ajustes manuales. No obstante, esta misma dependencia geométrica introduce variabilidad: trayectorias dispersas o con múltiples segmentos desconectados pueden provocar resultados subóptimos, al no capturar un único ancla la estructura completa del recorrido.

En términos de métricas de rendimiento, ATP evidencia una divergencia clara entre métricas puntuales y agregadas. Las primeras —como la distancia media, máxima y desviación estándar— presentan valores elevados y comportamientos irregulares, mientras que las métricas agregadas —como el error de longitud y el error de dirección— muestran una mejora sostenida. Este patrón sugiere que ATP prioriza la preservación de la forma y coherencia global de la trayectoria por encima de la precisión puntual, sacrificando exactitud local a cambio de

mantener la estructura general del movimiento.

Entre los resultados más relevantes, ATP logra el menor error de longitud entre los tres algoritmos comparados, alcanzando 11,285.32 metros en el nivel 5, lo que representa una mejora del 56 % respecto a Pivot Sampling y del 75 % respecto a Laplace. Este desempeño destaca su capacidad para mitigar la acumulación de errores independientes gracias a la correlación espacial introducida por el anclaje, conservando la consistencia métrica global del recorrido.

Sin embargo, esta ventaja viene acompañada de limitaciones notables. En particular, ATP no logra controlar adecuadamente las perturbaciones extremas: la distancia máxima oscila entre 1130.36 m y 1653.00 m, valores considerablemente superiores a los obtenidos por Laplace o Pivot Sampling. Esto ocurre cuando el radio calibrado $\hat{R}$ se amplía demasiado, incluyendo puntos distantes del ancla y generando desviaciones excesivas. Este fenómeno se acentúa en trayectorias con alta dispersión espacial, donde la expansión del dominio $\hat{P}_\alpha$ compromete las garantías de utilidad local.

En cuanto a la eficiencia computacional, ATP alcanza un equilibrio intermedio. Con tiempos de procesamiento entre 5.06 y 9.72 segundos, el algoritmo es entre 2.3 y 2.9 veces más rápido que Pivot Sampling, aunque continúa siendo alrededor de 600 veces más lento que Laplace. La mejora en eficiencia se debe principalmente a la reducción del número de candidatos dentro del dominio restringido y a la eliminación de los cálculos complejos de intersección angular característicos de Pivot Sampling. El patrón temporal, con forma de “U” invertida, sugiere que los niveles de presupuesto muy bajos y muy altos implican mayores costos computacionales, mientras que los niveles intermedios resultan más estables.

En síntesis, ATP se posiciona como un mecanismo de *privacidad diferencial local* adaptativo que prioriza la preservación estructural de la trayectoria mediante restricción espacial. Aunque introduce ventajas notables en la conservación de la forma global y eficiencia relativa, su rendimiento depende fuertemente de las características geométricas de la trayectoria y presenta vulnerabilidades frente a perturbaciones extremas. Por ello, ATP resulta especialmente adecuado para contextos de movilidad urbana donde los desplazamientos siguen patrones espaciales regulares, pero menos recomendable para escenarios con trayectorias dispersas o no estructuradas.

Capítulo 4

Análisis Experimental Graficas Origen-Destino

4.1. Descripción del Experimento y Parámetros de Configuración

El experimento se diseñó con el objetivo de evaluar el desempeño comparativo de tres mecanismos de privacidad diferencial aplicados a datos de trayectorias: el *Mecanismo de Laplace*, el *Pivot Sampling* (TP) y el *Anchor-Based Pivot Sampling* (ATP). Para ello, se utilizó el conjunto de datos **Geolife GPS Trajectories** desarrollado por Microsoft Research [14, 15, 16], el cual contiene registros de movilidad de 182 usuarios en la ciudad de Beijing recolectados durante más de tres años. De este conjunto, se seleccionaron **484 trayectorias reales** ubicadas en zonas próximas dentro del área urbana de Beijing, con el fin de facilitar la comparación espacial y reducir el sesgo geográfico durante el análisis. A partir de dichas trayectorias se construyeron matrices *Origen-Destino* (OD) tanto para los datos originales como para las versiones perturbadas generadas por cada algoritmo. Estas matrices permiten cuantificar la distorsión espacial introducida por los mecanismos de privacidad en términos de flujo entre celdas, sirviendo como base para el cálculo de las métricas de error analizadas.

4.1.1. Configuración del Presupuesto de Privacidad

En este experimento se utilizaron los mismos valores de ϵ definidos en el **Capítulo 3**, con el fin de mantener coherencia metodológica y permitir comparaciones directas entre ambos análisis.

De igual manera, se empleó nuevamente el parámetro k para los algoritmos basados en *privacidad diferencial local* (LDP), a fin de determinar el valor efectivo de ϵ en función de la cantidad de puntos N en cada trayectoria. En contraste, para el *Mecanismo de Laplace*, que implementa *privacidad diferencial central* (CDP), el valor de ϵ permanece fijo e independiente de N .

La Tabla 5.2 resume los valores utilizados en este experimento, correspondientes a los cinco

niveles de la escala unificada de privacidad (1 a 5) definida previamente.

Tabla 4.1: Configuración del presupuesto de privacidad utilizada en este capítulo. Se emplean los mismos valores de ϵ definidos en el Capítulo 3. Para los algoritmos basados en LDP, el presupuesto efectivo se calcula como $\epsilon_{\text{efectivo}} = k \times N$, donde N corresponde al número de puntos de cada trayectoria.

Nivel	Mecanismo de Laplace	Pivot Sampling / LDPTrace	Interpretación
1	$\epsilon = 0.01264$	$k = 1$ ($\epsilon_{\text{efectivo}} = N$)	Máxima privacidad
2	$\epsilon = 0.02148$	$k = 2$ ($\epsilon_{\text{efectivo}} = 2N$)	Privacidad alta
3	$\epsilon = 0.03032$	$k = 3$ ($\epsilon_{\text{efectivo}} = 3N$)	Balance moderado
4	$\epsilon = 0.03916$	$k = 4$ ($\epsilon_{\text{efectivo}} = 4N$)	Privacidad baja
5	$\epsilon = 0.04358$	$k = 5$ ($\epsilon_{\text{efectivo}} = 5N$)	Mínima privacidad

Esta configuración permite mantener la comparabilidad directa con los resultados presentados en el Capítulo 3, garantizando que las variaciones observadas en este análisis se deban únicamente al contexto experimental y no a diferencias en los parámetros de privacidad empleados.

4.1.2. Variación del tamaño de paso y análisis multiescala

Además del nivel de privacidad, el experimento incorporó un análisis multiescala para evaluar cómo la **resolución espacial** afecta la precisión y estabilidad de las métricas derivadas. El área de estudio fue discretizada mediante una malla geográfica regular en la que cada celda representa una unidad espacial homogénea utilizada para construir las matrices *Origen-Destino* (OD). El tamaño del lado de cada celda, definido por el parámetro `paso_m` (en metros), controla el grado de agregación espacial: valores menores generan una malla más densa y detallada, mientras que valores mayores producen una representación más agregada y menos sensible al ruido local. En este análisis se consideraron cinco niveles de resolución espacial:

Tabla 4.2: Valores del tamaño de paso utilizados en el experimento y su interpretación en términos de resolución espacial.

Tamaño de paso (m)	Interpretación
1000	Alta resolución / granularidad fina
1500	Resolución moderadamente alta
2000	Resolución media / balanceada
2500	Resolución baja / mayor agregación espacial
3000	Baja resolución / celdas amplias, suavización de distorsión

correspondientes a celdas cuadradas de 1 a 3 km de lado. De este modo, se abarcan escalas que permiten observar tanto los patrones locales de movilidad (alta resolución) como las tendencias más globales de flujo urbano (baja resolución).

Construcción conceptual de la malla espacial. El procedimiento general para generar la cuadrícula consiste en proyectar el área cubierta por las trayectorias dentro de un marco de

coordenadas geográficas (latitud y longitud), que luego se subdivide en intervalos regulares tanto en dirección norte–sur como este–oeste. Cada punto de las trayectorias se asigna a una celda específica según su posición, lo que permite contabilizar los desplazamientos entre celdas de origen y destino y construir así la matriz OD correspondiente.

A diferencia de una malla completa predefinida, en esta implementación las celdas se **generan dinámicamente** a medida que se procesan las coordenadas de las trayectorias. Cada vez que aparece una coordenada cuya celda aún no existe, se crea una nueva entrada en el mapa de celdas y se le asigna un identificador único. Este enfoque reduce la carga computacional y garantiza que solo se representen zonas efectivamente recorridas, evitando incluir áreas sin presencia de datos.

Para determinar la extensión de cada celda en grados, el tamaño de paso (en metros) se convierte mediante factores de escala aproximados:

$$1^{\circ}_{\text{lat}} \approx 111,000 \text{ m}, \quad 1^{\circ}_{\text{lon}} \approx 111,000 \cos(\varphi) \text{ m}$$

donde φ es la latitud media del área de estudio. Esta conversión permite definir la malla directamente en coordenadas geográficas sin requerir proyecciones cartográficas adicionales, garantizando una correspondencia métrica coherente en toda la región analizada.

Comportamiento teórico y empírico. El número total de celdas N_{celdas} varía inversamente con el cuadrado del tamaño de paso:

$$N_{\text{celdas}} \propto \frac{1}{\text{paso}_m^2}$$

lo que implica que duplicar el tamaño de celda reduce aproximadamente a una cuarta parte el número de unidades espaciales.

Empíricamente, esta relación se cumple de manera aproximada: el número exacto de celdas depende de la distribución espacial de las trayectorias (solo se contabilizan las celdas efectivamente ocupadas), de los efectos de redondeo en la discretización de coordenadas y de las pequeñas variaciones locales de latitud que modifican la escala longitudinal.

En conjunto, el análisis multiescala permite identificar la sensibilidad de las métricas de error frente a diferentes grados de agregación espacial, proporcionando una visión más completa del comportamiento de los mecanismos de privacidad bajo distintas resoluciones geográficas.

4.2. Construcción de las matrices OD y evaluación de resultados

Cada uno de los mecanismos se aplicó de forma independiente sobre las 484 trayectorias, generando versiones perturbadas bajo diferentes configuraciones de parámetros.

Posteriormente, se agruparon las posiciones perturbadas en celdas espaciales para conformar las matrices *Origen–Destino* (OD) correspondientes.

A partir de la comparación entre las matrices originales y las perturbadas, se calcularon las métricas de desempeño: *MAE*, *MAE normalizado*, *error relativo* y *norma de Frobenius*

normalizada.

Estas métricas permiten cuantificar tanto la distorsión local (por celda) como la coherencia estructural global del flujo de movilidad bajo cada configuración de privacidad.

En síntesis, este diseño experimental permite analizar de manera sistemática cómo la estructura geométrica de las trayectorias y la formulación del presupuesto de privacidad —ya sea central o local— influyen en la precisión y estabilidad de los mecanismos de perturbación evaluados.

4.2.1. Análisis de Resultados del Mecanismo de Laplace para Perturbación de Coordenadas

Los resultados experimentales del Mecanismo de Laplace se presentan para distintos valores del parámetro de privacidad ϵ y diferentes tamaños de paso espacial (1000 m, 1500 m, 2000 m, 2500 m y 3000 m). Las métricas utilizadas para la evaluación fueron el MAE, el MAE normalizado, el error relativo y la norma de Frobenius normalizada, con el fin de cuantificar el impacto de la perturbación sobre la fidelidad de las matrices Origen–Destino (OD).

De manera general, el comportamiento del Mecanismo de Laplace confirma la relación inversa entre el parámetro de privacidad ϵ y la magnitud del error: al aumentar ϵ , el ruido Laplaciano añadido disminuye, reduciendo gradualmente la distorsión en las matrices OD. Las cuatro métricas presentan tendencias decrecientes, aunque con leves fluctuaciones locales, particularmente en los pasos más amplios.

Se mantiene la coherencia con el principio de privacidad diferencial: los valores más bajos de ϵ (mayor ruido) generan desviaciones más pronunciadas, mientras que valores superiores a 0.03 conducen a errores estabilizados y consistentes. Además, el tamaño de paso tiene un efecto moderador: pasos de 1000–2000 m muestran mayor sensibilidad a las variaciones de ϵ , mientras que pasos de 2500–3000 m presentan curvas más planas debido a la agregación espacial, que suaviza los errores.

Análisis del MAE y MAE normalizado El MAE refleja la desviación media absoluta entre las matrices OD originales y perturbadas, mientras que su versión normalizada permite comparar entre escalas distintas. Ambos indicadores decrecen de forma sostenida conforme aumenta ϵ , confirmando que el ruido Laplaciano afecta menos a las coordenadas cuando el presupuesto de privacidad es mayor.

En los pasos de 1000 y 1500 m, el MAE presenta reducciones notables (de aproximadamente 1.4×10^{-2} a 3.5×10^{-3}), lo cual representa una mejora de más del 70 % en precisión. En pasos mayores, el error medio se mantiene en rangos más amplios, pero con estabilidad al incrementar ϵ , lo que indica que la agregación espacial mitiga las variaciones locales del ruido. El MAE normalizado reproduce esta misma tendencia con valores del orden de 10^{-4} , evidenciando un patrón decreciente uniforme entre configuraciones.

Análisis del error relativo El error relativo se calculó celda por celda, dividiendo el error absoluto entre el valor original de cada flujo OD, lo que proporciona una medida más precisa




Figura 4.1: Resultados del Algoritmo Laplace para Perturbación de Coordenadas. Se ilustran las métricas de error (MAE, MAE normalizado, error relativo y norma de Frobenius normalizada).

de proporcionalidad. Esta métrica presenta un descenso claro con el incremento de ϵ : desde valores cercanos a 0.45 hasta aproximadamente 0.11 para pasos de 1000 m, y de 0.33 a 0.11 en el caso de 1500 m. Ello indica que los flujos perturbados conservan su magnitud relativa respecto a los originales a medida que el ruido disminuye.

En pasos de 2500–3000 m, el error relativo alcanza mínimos en torno a 0.05, aunque este efecto se atribuye a la agregación espacial, que reduce las variaciones locales a costa de perder granularidad. Por lo tanto, configuraciones intermedias ($\epsilon \in [0.03, 0.04]$, pasos de 1500–2000 m) ofrecen el balance más adecuado entre detalle y estabilidad.

Análisis de la norma de Frobenius normalizada La *norma de Frobenius normalizada* cuantifica el error global en toda la matriz OD. Los resultados muestran un patrón decreciente sostenido conforme ϵ aumenta, con valores que van de aproximadamente 0.34 a 0.09 en pasos de 1000 m. En pasos intermedios (1500–2000 m), la métrica se estabiliza en torno a 0.10–0.20 cuando $\epsilon \geq 0.03$, indicando que las perturbaciones dejan de introducir distorsiones estructurales significativas en los flujos. El descenso en la norma de Frobenius refleja una mejora en la coherencia espacial global del sistema OD.

Interpretación integral de los resultados El análisis conjunto evidencia que el Mecanismo de Laplace mantiene un comportamiento predecible y estable en la perturbación de coordenadas. El patrón decreciente de las cuatro métricas confirma la reducción sistemática de error al aumentar el presupuesto de privacidad, validando empíricamente los principios teóricos de la privacidad diferencial geométrica.

Además, la comparación entre diferentes tamaños de paso sugiere que una granularidad intermedia (1500–2000 m) optimiza la relación entre precisión y estabilidad: pasos demasiado pequeños amplifican el efecto local del ruido, mientras que pasos grandes reducen el detalle espacial y suavizan excesivamente los flujos.

En síntesis, los resultados confirman que el Mecanismo de Laplace es eficaz para preservar la privacidad de coordenadas sin comprometer de forma significativa la utilidad de los datos. Las métricas muestran comportamientos decrecientes y estables para $\epsilon > 0.03$, con errores absolutos y relativos dentro de márgenes aceptables. Por tanto, se concluye que configuraciones con $\epsilon \in [0.03, 0.04]$ y pasos espaciales entre 1500 y 2000 m representan el punto de equilibrio óptimo entre privacidad y precisión, garantizando protección diferencial y coherencia estructural de los flujos OD.

4.2.2. Análisis de Resultados del Algoritmo Pivot Sampling para Privacidad en Trayectorias (TP)

El presente apartado analiza el desempeño del algoritmo *Pivot Sampling* aplicado a la generación de matrices Origen–Destino (OD) bajo distintos presupuestos de privacidad ϵ y diferentes granularidades espaciales (tamaños de paso). Cada combinación de parámetros fue evaluada empleando tres métricas de error: el *MAE normalizado*, el *error relativo* y la *norma de Frobenius normalizada*, las cuales cuantifican el grado de distorsión introducida en la matriz

OD respecto a la versión original. Los valores experimentales corresponden a la resta entre las matrices OD originales y las perturbadas obtenidas tras aplicar el mecanismo de privacidad.

En términos generales, los resultados confirman que el rendimiento del algoritmo *Pivot Sampling* mejora progresivamente al aumentar el presupuesto de privacidad ϵ , en coherencia con la teoría de la privacidad diferencial: a mayor ϵ , menor ruido inyectado y, por tanto, mayor fidelidad de los datos. Este comportamiento es visible en la disminución sostenida de las tres métricas de error entre $\epsilon = 1$ y $\epsilon = 5$, aunque con ligeras oscilaciones en algunos tamaños de paso.

El tamaño de paso (*paso.m*) también ejerce un efecto relevante sobre la estabilidad espacial del modelo. Los pasos pequeños (1000–1500 m) ofrecen alta resolución espacial pero presentan mayor variabilidad en los errores. En contraste, los pasos intermedios (2000–2500 m) logran un equilibrio más estable entre granularidad y consistencia, mientras que pasos grandes (3000 m) tienden a perder precisión estructural y aumentar el error global.

Análisis del MAE y MAE normalizado El MAE y su versión *normalizada* reflejan la magnitud media del error absoluto entre los flujos OD originales y los perturbados, expresados respectivamente en unidades absolutas y relativas al total de flujos. Ambas métricas exhiben una tendencia general decreciente con el aumento del presupuesto de privacidad ϵ , lo que confirma que una menor intensidad de ruido conduce a reconstrucciones más precisas de los patrones de movilidad.

En pasos pequeños (1000 m), el MAE desciende de 0.0167 para $\epsilon = 1$ a 0.0081 en $\epsilon = 4$, con un leve aumento posterior en $\epsilon = 5$. Este comportamiento se replica en el MAE normalizado, que pasa de 2.78×10^{-4} a 1.26×10^{-4} , indicando una reducción cercana al 55 % en el error medio. Sin embargo, la tendencia no es estrictamente monótona, ya que en algunos casos el incremento del presupuesto de privacidad produce ligeras oscilaciones, atribuibles a la naturaleza estocástica del muestreo pivotado y a la influencia del tamaño de las celdas.

El valor mínimo global de ambas métricas se registra para $\epsilon = 5$ y paso de 2000 m, con $MAE = 0.0408$ y $MAE_{norm} = 3.19 \times 10^{-4}$. Esta configuración evidencia que, con un presupuesto de privacidad alto y una granularidad intermedia, el algoritmo logra preservar de manera efectiva la coherencia espacial de los flujos OD.

Por otra parte, en pasos grandes (3000 m), tanto el MAE como su versión normalizada tienden a incrementarse nuevamente, alcanzando valores de hasta 0.29 y 2.10×10^{-3} respectivamente. Esto se debe al efecto de sobre-agregación espacial, donde la pérdida de detalle direccional y la compensación entre flujos adyacentes degradan la precisión de la matriz reconstruida.

En conclusión, el análisis conjunto del MAE y el MAE normalizado demuestra que la precisión del algoritmo mejora consistentemente con el aumento de ϵ y que los pasos intermedios (2000–2500 m) representan el punto óptimo de balance entre granularidad y estabilidad de los resultados.




Figura 4.2: Resultados del Algoritmo Pivot Sampling para Privacidad en Trayectorias (TP). Se ilustran las tres métricas de error (MAE normalizado, error relativo y norma de Frobenius normalizada).

Análisis del error relativo El *error relativo* evalúa la magnitud del error respecto al total de flujos originales. Los resultados muestran una reducción significativa al aumentar ϵ , pasando de valores cercanos a 0.50 para $\epsilon = 1$ a mínimos cercanos a 0.09–0.13 para $\epsilon \in [4, 5]$. El menor valor reportado ($Error_{rel} = 0.0877$) se presenta en $\epsilon = 4$ y paso de 2500 m, lo que representa una reducción del error de aproximadamente 82

Se observa, además, que los pasos intermedios (2000–2500 m) ofrecen los mejores compromisos entre error y estabilidad espacial, evitando tanto la atomización excesiva de flujos (en pasos pequeños) como la pérdida de resolución direccional (en pasos grandes).

Análisis de la norma de Frobenius normalizada La norma de Frobenius normalizada cuantifica el error acumulado global sobre la estructura completa de la matriz OD. De manera consistente con las métricas anteriores, se observa una reducción clara con el aumento de ϵ . El valor mínimo se alcanza para $\epsilon = 5$ y paso de 2500 m, con una norma de Frobenius normalizada de 0.0631, lo que implica que la matriz perturbada conserva más del 93

Los pasos entre 2000 y 2500 m aparecen nuevamente como los más equilibrados, mostrando una disminución estable y sostenida de la norma de Frobenius sin degradación abrupta en ningún rango de ϵ .

Interpretación integral de los resultados En conjunto, las tres métricas confirman que la precisión del algoritmo *Pivot Sampling* depende de la interacción entre el presupuesto de privacidad ϵ y la granularidad espacial. Para valores bajos de ϵ , el ruido angular y posicional aplicado a los pivotes introduce distorsiones significativas que afectan la coherencia espacial de las trayectorias. A medida que ϵ aumenta, el mecanismo preserva con mayor fidelidad la dirección y magnitud de los desplazamientos, reduciendo los errores en las matrices OD.

El tamaño de paso actúa como un regulador de la sensibilidad al ruido: pasos pequeños maximizan la resolución espacial pero amplifican la varianza del error, mientras que pasos grandes suavizan los resultados a costa de perder detalle. Los valores intermedios (entre 2000 y 2500 m) junto con un presupuesto de privacidad alto ($\epsilon \in [4, 5]$) conforman la configuración óptima, alcanzando reducciones globales del error superiores al 75

En síntesis, el algoritmo *Pivot Sampling* mantiene un desempeño sólido frente a la perturbación diferencial local. El aumento del presupuesto de privacidad ϵ mejora de forma consistente la precisión de las matrices Origen–Destino, mientras que un tamaño de paso intermedio favorece la estabilidad del modelo. Los resultados experimentales evidencian que la estrategia de muestreo pivotado logra preservar la coherencia estructural de los flujos de movilidad incluso bajo niveles de ruido moderados

4.2.3. Análisis de Resultados del Algoritmo Anchor-Based Pivot Sampling (ATP)

En esta sección se analiza el desempeño experimental del algoritmo *Anchor-Based Pivot Sampling* (ATP), diseñado para preservar la privacidad diferencial geométrica en trayectorias mediante la incorporación de pivotes anclados que reducen la dispersión direccional de los

puntos perturbados. Se evaluaron distintas configuraciones del presupuesto de privacidad ϵ (representado por k) y del tamaño de paso espacial (1000, 1500, 2000, 2500 y 3000 m). Las métricas consideradas fueron el *MAE*, el *MAE normalizado*, el *error relativo* y la *norma de Frobenius normalizada*, con el fin de cuantificar la distorsión introducida sobre las matrices Origen–Destino (OD) generadas por el mecanismo.

De forma general, el algoritmo *ATP* presenta un comportamiento más estable que el *Pivot Sampling* tradicional, aunque con variaciones notables según el tamaño de paso. A diferencia de los resultados obtenidos en el método TP, aquí no se observa una disminución estrictamente monótona de los errores al incrementar ϵ . Las métricas tienden a oscilar levemente, especialmente en pasos pequeños e intermedios (1000–2500 m), lo que sugiere una interacción compleja entre el nivel de ruido, el anclaje y la granularidad espacial.

En pasos grandes (3000 m), sin embargo, el comportamiento se estabiliza de manera clara: todas las métricas de error disminuyen progresivamente al aumentar ϵ , evidenciando que el mecanismo de anclaje es más efectivo cuando las celdas son amplias y las trayectorias presentan menos variabilidad direccional.

Análisis del MAE y MAE normalizado El *MAE* y su versión *normalizada* muestran una tendencia irregular en pasos menores a 2500 m. Por ejemplo, para paso de 1000 m, los valores se mantienen en torno a $MAE \approx 0.026$ y $MAE_{norm} \approx 4 \times 10^{-4}$, sin una reducción clara con el incremento de ϵ . Una situación similar ocurre para pasos de 1500 m y 2000 m, donde los errores fluctúan entre 0.09 y 0.21 en MAE, indicando que el mecanismo introduce una magnitud de perturbación casi constante independientemente del presupuesto de privacidad.

El mejor desempeño se observa en pasos de 3000 m, donde el MAE disminuye gradualmente de 0.498 para $\epsilon = 1$ a 0.367 para $\epsilon = 5$, y el MAE normalizado pasa de 3.4×10^{-3} a 2.5×10^{-3} . Esto sugiere que el anclaje mejora su efecto en escenarios de mayor agregación espacial, donde el ruido se distribuye de forma más homogénea.

Por otro lado, los pasos intermedios (2500 m) presentan los mayores errores absolutos ($MAE \approx 0.6$), posiblemente debido a una combinación de pérdida de detalle espacial y ruido direccional residual entre pivotes cercanos, lo que genera una ligera sobreperturbación en los flujos agregados.

Análisis del error relativo El *error relativo* presenta un patrón similar al MAE: alto y oscilante en pasos pequeños e intermedios, con tendencia descendente únicamente en pasos grandes. Para pasos de 1000–2000 m, los valores se mantienen entre 0.60 y 0.70, sin una reducción significativa al aumentar ϵ . En contraste, para paso de 3000 m, el error relativo disminuye desde 0.63 en $\epsilon = 1$ hasta 0.47 en $\epsilon = 5$, representando una mejora de alrededor del 25 %.

Esto indica que, en configuraciones más agregadas, el algoritmo logra conservar mejor las proporciones entre flujos OD, beneficiándose del efecto de promediación espacial generado por el anclaje.




Figura 4.3: Resultados del Algoritmo Anchor-Based Pivot Sampling (ATP). Se ilustran las métricas de error (MAE, MAE normalizado, error relativo y norma de Frobenius normalizada).

Análisis de la norma de Frobenius normalizada La *norma de Frobenius normalizada*, que mide el error global de toda la matriz OD, muestra el patrón más coherente entre las métricas. Aunque los valores iniciales son relativamente altos para pasos pequeños (≈ 0.6), la magnitud del error se reduce progresivamente al aumentar el tamaño de celda, alcanzando sus mínimos globales en pasos de 3000 m (0.125 para $\epsilon = 5$).

Esto demuestra que, a escalas espaciales amplias, el anclaje contribuye a mantener la estructura global de los flujos, reduciendo la dispersión acumulada y las inconsistencias direccionales entre trayectorias perturbadas.

Interpretación integral de los resultados El conjunto de resultados sugiere que el mecanismo *ATP* no siempre reduce los errores con el aumento de ϵ en escalas finas, pero sí mejora de forma consistente la estabilidad en escalas más agregadas. El anclaje introduce una dependencia espacial entre los pivotes que atenúa las distorsiones locales, aunque esta ventaja se manifiesta plenamente solo cuando las celdas son lo suficientemente grandes para absorber el ruido direccional.

Por tanto, el *ATP* se comporta como un mecanismo eficaz en contextos de análisis macroscópico de movilidad, donde la prioridad es preservar la coherencia estructural general de las trayectorias más que los detalles locales de corto alcance.

En síntesis, los resultados experimentales evidencian que el algoritmo *Anchor-Based Pivot Sampling (ATP)* mantiene un equilibrio razonable entre privacidad y utilidad, aunque su rendimiento óptimo se alcanza para configuraciones de paso grande (3000 m) y valores altos de ϵ (≥ 4). En este régimen, las tres métricas de error convergen hacia sus mínimos, con reducciones de hasta un 30 % respecto a los valores iniciales.

El anclaje espacial de pivotes permite una mejor conservación de la estructura global de las matrices OD, reduciendo la dispersión acumulada sin comprometer la consistencia geométrica de las trayectorias. Por consiguiente, el *ATP* se perfila como un método adecuado para escenarios donde se privilegia la estabilidad estructural global sobre la precisión local.

4.3. Comparación Global de los Mecanismos de Privacidad Diferencial

En esta sección se presenta un análisis comparativo integral entre los tres mecanismos evaluados: el *Mecanismo de Laplace para Perturbación de Coordenadas*, el *Pivot Sampling (TP)* y el *Anchor-Based Pivot Sampling (ATP)*. El objetivo es contrastar su comportamiento frente a las métricas de error (*MAE*, *MAE normalizado*, *error relativo* y *norma de Frobenius normalizada*) considerando la influencia del presupuesto de privacidad ϵ y del tamaño de paso espacial.

El análisis global revela tres patrones de desempeño diferenciados. El *Mecanismo de Laplace* exhibe una tendencia decreciente clara y regular en todas las métricas conforme aumenta ϵ , con un comportamiento predecible y estable. Esto se debe a que el ruido Laplaciano se aplica de manera uniforme e independiente sobre cada coordenada, generando perturbaciones localmente

acotadas y sin correlación espacial. En consecuencia, sus errores disminuyen de forma monótona y controlada, alcanzando valores mínimos estables para $\epsilon \geq 0.03$.

En contraste, el algoritmo *Pivot Sampling* introduce mayor variabilidad en los resultados debido a la naturaleza direccional del ruido aplicado a los pivotes. Aunque sigue la misma tendencia general de reducción de error con el aumento de ϵ , las fluctuaciones son más notorias en pasos pequeños. El muestreo pivotado genera desplazamientos dependientes del contexto geométrico de las trayectorias, lo que incrementa la sensibilidad a la granularidad espacial. No obstante, en configuraciones con pasos intermedios (2000–2500 m) y altos valores de ϵ , el algoritmo logra un equilibrio notable entre precisión y coherencia estructural, con reducciones globales del error de hasta 80 %.

Finalmente, el mecanismo *Anchor-Based Pivot Sampling* (ATP) muestra un patrón de comportamiento más complejo. El uso de pivotes anclados introduce correlaciones espaciales que estabilizan parcialmente la distorsión direccional, pero la magnitud del error no disminuye de manera estrictamente monótona con ϵ . En escalas finas (1000–2000 m), el anclaje genera oscilaciones locales por la interacción entre ruido direccional y dependencia espacial; sin embargo, en pasos grandes (3000 m), el algoritmo se estabiliza y supera en consistencia global al TP, con reducciones de error cercanas al 30 %.

Comparación del MAE y MAE normalizado En términos de error medio (*MAE*) y su versión normalizada, el Mecanismo de Laplace mantiene los valores absolutos más bajos para configuraciones de alta privacidad (bajo ϵ), lo que lo posiciona como el método más estable en escenarios de ruido intenso. El *Pivot Sampling* logra mejorar progresivamente su precisión conforme aumenta ϵ , alcanzando su mejor desempeño en pasos intermedios, donde la relación entre resolución espacial y ruido angular es más equilibrada. Por su parte, el ATP presenta una reducción efectiva del MAE únicamente en pasos amplios, indicando que su mecanismo de anclaje es más eficiente a nivel macroscópico que en escalas locales.

En resumen, el Laplace domina en precisión local, el TP en estabilidad a resolución media, y el ATP en coherencia estructural cuando la agregación espacial es mayor.

Comparación del error relativo El *error relativo* refuerza estas conclusiones. El Mecanismo de Laplace reduce de forma uniforme la proporción de error con el incremento de ϵ , alcanzando mínimos cercanos a 0.05 en configuraciones agregadas. El *Pivot Sampling* logra valores similares (en torno a 0.08–0.10) cuando $\epsilon \geq 4$ y el tamaño de paso se sitúa entre 2000 y 2500 m, reflejando una buena conservación de las proporciones de flujo OD. El ATP, en cambio, mantiene errores relativos más altos en pasos finos (entre 0.60 y 0.70), pero mejora significativamente en pasos de 3000 m, donde el error relativo cae hasta 0.47; esto sugiere que el anclaje redistribuye el ruido de manera más homogénea en contextos de menor resolución.

Comparación de la norma de Frobenius normalizada La *norma de Frobenius normalizada* permite evaluar la preservación global de la estructura de las matrices OD. El Laplace muestra el descenso más uniforme y sostenido, con mínimos cercanos a 0.09 en pasos de 1500–2000 m.

El Pivot Sampling logra un desempeño comparable, alcanzando valores mínimos de 0.06–0.07 en configuraciones óptimas de $\epsilon = 5$ y paso intermedio. Por su parte, el ATP reduce su norma de Frobenius de 0.58 a 0.12 en pasos de 3000 m, consolidándose como el método más robusto en términos de preservación estructural global, aunque no necesariamente el más preciso localmente.

Interpretación integral y síntesis comparativa Desde una perspectiva integral, los tres mecanismos se complementan en su rango de aplicación:

- **Laplace**: óptimo para perturbación de coordenadas individuales o estudios de alta resolución espacial, donde se requiere una relación directa y controlada entre privacidad y precisión.
- **Pivot Sampling (TP)**: adecuado para trayectorias con resolución media, donde la dirección del movimiento es relevante y se busca conservar la coherencia local sin sobreagregar los datos.
- **Anchor-Based Pivot Sampling (ATP)**: más eficiente en análisis macroscópicos o agregados, donde la prioridad es mantener la estructura global de flujos y minimizar la distorsión acumulativa entre zonas.

En conclusión, la comparación evidencia un gradiente de especialización entre los mecanismos: el *Laplace* ofrece precisión local bajo alta privacidad, el *Pivot Sampling* equilibra privacidad y utilidad en contextos intermedios, y el *ATP* maximiza la estabilidad estructural global cuando se privilegia la coherencia espacial sobre el detalle individual. Por tanto, la elección del mecanismo más adecuado dependerá del nivel de agregación espacial y del tipo de análisis de movilidad que se desee preservar bajo el marco de la privacidad diferencial geométrica.

Capítulo 5

Análisis Grafico de las Trayectorias

En este capítulo se presenta la herramienta desarrollada para la visualización interactiva de trayectorias GPS y la evaluación gráfica del efecto de los mecanismos de privacidad diferencial. La herramienta se encuentra disponible públicamente en: https://cflorido.github.io/front_thesis/.

La aplicación permite al usuario:

- Seleccionar el **algoritmo** de privacidad diferencial a analizar: Mecanismo de Laplace, Pivot Sampling (TP) o Anchor-Based Pivot Sampling (ATP).
- Elegir el **tipo de visualización** deseada, entre varias opciones que se detallan más adelante.
- Ajustar los **parámetros del experimento**: el tamaño de paso (`paso_m`) y el presupuesto de privacidad (ϵ).
- Alternar la visualización entre los datos **originales** y los datos **perturbados**.

5.1. Parámetros de Configuración

Para mantener consistencia con los experimentos previos, se utilizan los mismos valores de tamaño de paso y presupuesto de privacidad definidos en el Capítulo 3.

Tabla 5.1: Valores del tamaño de paso utilizados en el experimento y su interpretación en términos de resolución espacial.

Tamaño de paso (m)	Interpretación
1000	Alta resolución / granularidad fina
1500	Resolución moderadamente alta
2000	Resolución media / balanceada
2500	Resolución baja / mayor agregación espacial
3000	Baja resolución / celdas amplias, suavización de distorsión

Tabla 5.2: Configuración del presupuesto de privacidad utilizada en este capítulo. Para los algoritmos basados en LDP, el presupuesto efectivo se calcula como $\epsilon_{\text{efectivo}} = k \times N$, donde N corresponde al número de puntos de cada trayectoria.

Nivel	Mecanismo de Laplace	Pivot Sampling / LDPTTrace	Interpretación
1	$\epsilon = 0.01264$	$k = 1$ ($\epsilon_{\text{efectivo}} = N$)	Máxima privacidad
2	$\epsilon = 0.02148$	$k = 2$ ($\epsilon_{\text{efectivo}} = 2N$)	Privacidad alta
3	$\epsilon = 0.03032$	$k = 3$ ($\epsilon_{\text{efectivo}} = 3N$)	Balance moderado
4	$\epsilon = 0.03916$	$k = 4$ ($\epsilon_{\text{efectivo}} = 4N$)	Privacidad baja
5	$\epsilon = 0.04358$	$k = 5$ ($\epsilon_{\text{efectivo}} = 5N$)	Mínima privacidad

5.2. Tipos de Visualización

La herramienta desarrollada permite explorar los datos de trayectorias y sus perturbaciones mediante cinco tipos de visualización, cada uno con un enfoque distinto sobre la estructura espacial y los flujos de movilidad:

1. **Matriz Origen–Destino (OD):** Esta visualización representa la cantidad de trayectorias que se mueven desde una celda de origen a una celda de destino. Cada elemento (i, j) de la matriz indica el flujo de trayectorias entre las celdas correspondientes. Permite identificar rutas frecuentes y patrones de movilidad agregados. Comparando la matriz original con la perturbada se puede evaluar cómo los mecanismos de privacidad afectan la preservación de los flujos.




Figura 5.1: Ejemplo de matriz Origen–Destino generada por la herramienta.

2. **Mapa de calor de celdas destino:** Cada celda se colorea según la cantidad de trayectorias que terminan en ella, generando un mapa de densidad de llegadas. Las celdas con colores mas cercanos al amarillo representan destinos frecuentes y permiten visualizar concentración de actividad en la ciudad. Esta visualización ayuda a identificar zonas críticas de destino y evaluar cómo la perturbación de datos puede alterar la percepción de concentración espacial.




Figura 5.2: Mapa de calor de celdas destino.

3. **Mapa de calor de celdas origen:** Similar al anterior, pero considerando el punto de inicio de las trayectorias. Permite identificar los principales puntos de partida de los movimientos y cómo los mecanismos de privacidad afectan la visibilidad de los patrones de inicio.




Figura 5.3: Mapa de calor de celdas Origen.

4. **Mapa combinado de flujos Origen–Destino:** Combina un mapa de calor de celdas origen (escala azul) y destino (escala roja), junto con líneas de flujo que conectan las celdas de inicio y fin de cada trayectoria. Proporciona una visión integral de concentración espacial y dirección de los movimientos, siendo crítico para entender tanto la intensidad como la dirección de los desplazamientos y cómo los mecanismos de privacidad modifican la estructura de los flujos.




Figura 5.4: Mapa combinado de flujos Origen–Destino con superposición de celdas origen y destino.

5. **Diferencia absoluta por celda entre matriz OD original y perturbada:** Cada celda representa la diferencia en número de trayectorias entre los datos originales y los perturbados. Los colores más amarillos indican mayor distorsión en esa celda, permitiendo localizar espacialmente dónde los mecanismos de privacidad introducen mayores cambios. Esta visualización es esencial para evaluar el impacto de la privacidad diferencial a nivel granular y para identificar patrones de distorsión específicos inducidos por cada algoritmo.




Figura 5.5: Mapa de diferencia absoluta por celda entre matriz OD original y perturbada.

5.3. Interacción con la Herramienta

La interfaz permite al usuario:

- Alternar entre las visualizaciones mencionadas para observar cómo cambian los patrones espaciales según el tipo de análisis.




Figura 5.6: Botón para alternar visualizaciones.

- Modificar el tamaño de paso (paso_m) y el presupuesto de privacidad (ϵ) para estudiar la sensibilidad de los resultados a estos parámetros.



Figura 5.7: Panel para cambiar parámetros de visualización y privacidad.

- Comparar los datos originales frente a los perturbados, lo cual permite evaluar visualmente el impacto de cada mecanismo de privacidad diferencial.




Figura 5.8: Interfaz para alternar entre datos originales y perturbados.

- Seleccionar el algoritmo de privacidad que se desea analizar.




Figura 5.9: Selector de algoritmo en la interfaz.

- Hacer click sobre cada celda en todas las visualizaciones para obtener información adicional, como el valor de la celda, el ID de la celda o los viajes correspondientes.




Figura 5.10: Información adicional al hacer click sobre una celda.

5.4. Consideraciones finales

Esta herramienta facilita la exploración multiescala de trayectorias y la evaluación gráfica de los mecanismos de privacidad diferencial. La combinación de selección de algoritmo, ajuste de parámetros y distintos tipos de visualización permite un análisis completo de la distorsión espacial y los patrones de movilidad en los datos GPS.

Capítulo 6

Conclusiones y Trabajo Futuro

El presente trabajo abordó el problema de la protección de la privacidad en datos de ubicación mediante la aplicación de mecanismos de *Privacidad Diferencial* (LD). A lo largo del estudio se desarrolló una evaluación comparativa entre diferentes estrategias de perturbación —entre ellas el Mecanismo de Laplace, Pivot Sampling (TP) y Anchor-Based Pivot Sampling (ATP)— con el fin de analizar su impacto sobre la utilidad de los datos y su capacidad para preservar patrones espaciales significativos.

El marco experimental incluyó tanto métricas cuantitativas (distancia media, desviación estándar, error angular, entre otras) como representaciones visuales interactivas que facilitaron la comprensión de los efectos de cada mecanismo sobre las trayectorias GPS. Esta combinación permitió obtener una visión integral del compromiso entre privacidad y utilidad, ofreciendo un enfoque robusto para el análisis de datos espaciales bajo condiciones de anonimización.

6.1. Discusión de Resultados

Los resultados obtenidos evidencian que el Mecanismo de Laplace, aunque conceptualmente simple y ampliamente utilizado, introduce una distorsión considerable en trayectorias con estructuras espaciales finas, especialmente cuando el presupuesto de privacidad ϵ es bajo. En contraste, los mecanismos basados en puntos pivote (TP y ATP) logran una mejor conservación de la topología del movimiento, manteniendo la coherencia espacial y la continuidad de las trayectorias incluso bajo niveles de privacidad más estrictos.

En particular, el mecanismo *Anchor-Based Pivot Sampling* (ATP) demostró una mayor estabilidad ante el incremento del número de puntos, lo cual lo hace más adecuado para escenarios con trayectorias densas o de larga duración. Este comportamiento sugiere que las técnicas basadas en anclajes espaciales pueden ofrecer un mejor equilibrio entre preservación estructural y protección de la privacidad.

El análisis visual complementó los resultados numéricos, revelando cómo la forma y la distribución de las trayectorias cambian a medida que se reduce el presupuesto de privacidad. La distorsión se manifiesta de forma no uniforme en el espacio, siendo más pronunciada en zonas con mayor densidad de movimiento. Estos hallazgos refuerzan la necesidad de adaptar

los mecanismos de perturbación al contexto espacial de los datos.

6.2. Herramienta de Visualización

La herramienta de visualización desarrollada constituye una contribución práctica y metodológica relevante. Permite explorar de forma interactiva la relación entre el nivel de privacidad y la distorsión espacial introducida, ofreciendo soporte visual para la interpretación de resultados experimentales.

Su diseño modular y multiplataforma facilita la integración de nuevos mecanismos de privacidad y la extensión hacia diferentes tipos de datos geográficos. En consecuencia, la herramienta puede emplearse tanto en entornos de investigación como en escenarios educativos, para ilustrar de manera intuitiva los principios de la privacidad diferencial y su impacto en el análisis de trayectorias.

6.3. Aplicaciones Potenciales

Los resultados y las herramientas desarrolladas en esta tesis ofrecen un amplio potencial de aplicación en ámbitos donde la información geográfica constituye un insumo esencial, pero donde la protección de la privacidad individual es igualmente prioritaria. Entre las áreas más relevantes se encuentran la movilidad urbana, la gestión del tráfico vehicular, la planificación del transporte público, la evaluación del impacto ambiental de los desplazamientos y los estudios de comportamiento espacial de la población.

Las matrices origen–destino (OD) generadas a partir de los datos perturbados representan una herramienta particularmente valiosa. Permiten estimar flujos de movilidad agregados entre zonas geográficas sin necesidad de acceder a trayectorias individuales, lo cual resulta crucial para entidades públicas y privadas que requieren analizar la demanda de transporte, diseñar rutas óptimas o evaluar la eficiencia de la infraestructura existente. Gracias a la aplicación de mecanismos de privacidad diferencial local, estas matrices conservan la utilidad estadística necesaria para la toma de decisiones, al tiempo que reducen significativamente el riesgo de reidentificación de los usuarios.

De igual manera, los mapas visuales construidos en la herramienta desarrollada permiten observar de forma intuitiva la distribución espacial de los desplazamientos y las alteraciones introducidas por los distintos mecanismos de perturbación. Estas visualizaciones pueden ser utilizadas por investigadores y planificadores urbanos para comprender el comportamiento de los mecanismos bajo distintos parámetros de privacidad, identificar patrones de movilidad agregados o comunicar resultados de forma comprensible a audiencias no técnicas. La posibilidad de comparar trayectorias originales y perturbadas facilita además la evaluación cualitativa del equilibrio entre privacidad y utilidad.

En un contexto más amplio, los métodos y visualizaciones implementados en esta tesis pueden integrarse en plataformas de análisis geoespacial que requieran compartir datos sensibles de localización —por ejemplo, en aplicaciones de ciudades inteligentes, monitoreo de flujos

turísticos o estudios de accesibilidad territorial—, cumpliendo con normativas de protección de datos y principios éticos de manejo de información personal. En síntesis, este trabajo no solo demuestra la viabilidad técnica de aplicar privacidad diferencial local a datos de movilidad, sino que también abre el camino hacia herramientas prácticas para un uso responsable y seguro de la información espacial en la investigación y la gestión pública.

6.4. Limitaciones del Estudio

Aunque los experimentos se realizaron sobre trayectorias reales de usuarios, el estudio presenta limitaciones que deben tenerse en cuenta al interpretar los resultados. En primer lugar, si bien los datos son reales, el análisis se centró en un subconjunto representativo y en contextos urbanos concretos, lo que puede introducir sesgos geográficos y de comportamiento que limitan la generalización a otras ciudades, contextos rurales o patrones de movilidad diferentes. En segundo lugar, aunque las trayectorias individuales son auténticas, el estudio no modeló de forma exhaustiva las interdependencias espaciales y temporales entre múltiples usuarios —por ejemplo, coincidencias espacio-temporales entre trayectorias o efectos de multitudes—, factores que en despliegues reales pueden influir en el riesgo de reidentificación y en la eficacia de los mecanismos de perturbación. En tercer lugar, la dimensión temporal fue tratada de forma limitada: no se exploraron en detalle variaciones en la frecuencia de muestreo, estacionalidad ni dinámicas temporales complejas que podrían alterar tanto la utilidad como las garantías de privacidad en aplicaciones operativas. Finalmente, existen restricciones prácticas relacionadas con la selección y calibración de parámetros (elección de ϵ , radios adaptativos, granularidad espacial) y con la escalabilidad computacional de los métodos más sofisticados; dichas limitaciones condicionan la viabilidad de desplegar algunas variantes del algoritmo en entornos con grandes volúmenes de datos o requisitos de latencia estrictos.

Asimismo, el análisis se centró en la dimensión espacial, dejando abierta la posibilidad de incorporar la dimensión temporal para evaluar el impacto de la privacidad en series de tiempo o trayectorias con alta frecuencia de muestreo.

6.5. Trabajo Futuro

Como trabajo futuro, se propone extender el estudio hacia contextos dinámicos donde el nivel de privacidad varíe de forma adaptativa en función de la sensibilidad del entorno o del tipo de usuario. También sería pertinente evaluar el comportamiento de modelos de aprendizaje automático entrenados sobre datos perturbados, analizando cómo los distintos mecanismos de LDP afectan la capacidad predictiva o la calidad del clustering espacial.

Otra línea de investigación relevante consiste en explorar la combinación de enfoques probabilísticos con representaciones espaciales basadas en grafos o redes neuronales geográficas. Esto permitiría construir modelos híbridos que preserven patrones globales mientras mantienen la privacidad individual.

Finalmente, se considera valioso continuar el desarrollo de la herramienta de visualización

para incorporar funcionalidades analíticas avanzadas, como la comparación automática entre mecanismos, la generación de métricas de fidelidad espacial o la simulación de escenarios de privacidad personalizados.

6.6. Conclusión Final

En conclusión, esta tesis contribuye al entendimiento del impacto de la privacidad diferencial local sobre los datos de ubicación, ofreciendo tanto un análisis empírico de su comportamiento como una herramienta práctica de visualización e interpretación. El equilibrio entre privacidad y utilidad se consolida como un desafío fundamental en la era de los datos ubicuos, y los mecanismos evaluados en este trabajo representan un paso significativo hacia soluciones más seguras, transparentes y éticamente responsables.

Bibliografía

- [1] New York University, "How apps track you." <https://www.nyu.edu/life/information-technology/safe-computing/checklists-guides/guides/software-hardware/app-tracking.html>, s.f. Cyber Smart Guides, consultado el 8 de noviembre de 2025.
- [2] Y.-A. de Montjoye, C. A. Hidalgo, M. Verleysen, and V. D. Blondel, "Unique in the crowd: The privacy bounds of human mobility," *Scientific Reports*, vol. 3, p. 1376, 2013.
- [3] B. Quan, X. Mia, and A. Okunola, "Navigating gdpr and ccpa compliance in business analytics: Analyzing the impact on business analytics practices," s.f., pp.—, 12 2024.
- [4] C. Dwork, F. McSherry, K. Nissim, and A. Smith, "Calibrating noise to sensitivity in private data analysis," in *Theory of Cryptography: 3rd Theory of Cryptography Conference, TCC 2006, Proceedings*, pp. 265–284, Springer, 2006.
- [5] Apple Inc., "Understanding aggregate trends for apple intelligence using differential privacy." <https://machinelearning.apple.com/research/differential-privacy-aggregate-trends>, April 14 2025. Consultado el 12 de noviembre de 2025.
- [6] Google Cloud, "Differential privacy in bigquery." <https://docs.cloud.google.com/bigquery/docs/differential-privacy?hl=es-419>, 2025. Consultado el 12 de noviembre de 2025.
- [7] J. Mervis, "The u.s. has a new way to mask census data in the name of privacy. how does it affect accuracy?," *ScienceInsider*, May 3 2024. doi: 10.1126/science.zbp0e8r, consultado el 13 de noviembre de 2025.
- [8] C. Dwork, "Differential privacy: A survey of results," in *Theory and Applications of Models of Computation. TAMC 2008* (M. Agrawal, D. Du, Z. Duan, and A. Li, eds.), vol. 4978 of *Lecture Notes in Computer Science*, pp. 1–19, Springer, 2008.
- [9] C. Dwork and A. Roth, *The Algorithmic Foundations of Differential Privacy*, vol. 9. Now Publishers Inc., 2014. Microsoft Research, USA and University of Pennsylvania, USA.

- [10] X. Lyu, "Composition theorems for interactive differential privacy," *arXiv preprint arXiv:2207.09397*, 2022. Department of Electrical Engineering and Computer Science, University of California, Berkeley.
- [11] D. Quan, L. Yin, and Y. Guo, "Enhancing the trajectory privacy with laplace mechanism," in *2015 IEEE Trustcom/BigDataSE/ISPA*, pp. 758–765, Institute of Information Engineering, Chinese Academy of Sciences, IEEE, 2015.
- [12] Y. Zhang, Q. Ye, R. Chen, H. Hu, and Q. Han, "Trajectory data collection with local differential privacy," *Proceedings of the VLDB Endowment*, vol. 16, no. 10, pp. 2591–2604, 2023.
- [13] D. Brockmann, L. Hufnagel, and T. Geisel, "The scaling laws of human travel," *Nature*, vol. 439, pp. 462–465, 2006.
- [14] Y. Zheng, L. Liu, L. Wang, and X. Xie, "Understanding mobility based on gps data," in *Proceedings of the 10th International Conference on Ubiquitous Computing (UbiComp 2008)*, (Seoul, South Korea), pp. 312–321, ACM, 2008.
- [15] Y. Zheng, Q. Li, Y. Chen, X. Xie, and W.-Y. Ma, "Mining interesting locations and travel sequences from gps trajectories," in *Proceedings of the 18th International Conference on World Wide Web (WWW 2009)*, (Madrid, Spain), pp. 791–800, ACM, 2009.
- [16] Y. Zheng, X. Xie, and W.-Y. Ma, "Geolife: A collaborative social networking service among user, location and trajectory," *IEEE Data Engineering Bulletin*, vol. 33, no. 2, pp. 32–39, 2010.